



DESENVOLVIMENTO INICIAL DE UMA API E UMA INTERFACE WEB PARA ANÁLISE DE DOMÍNIO BASEADA EM MINERAÇÃO DE TEXTO EM PYTHON

Matheus Mendes Lourenço¹, Lincoln Maggini Mauro¹, Héber Renato Fadel de Moraes¹, Elismar Vicente dos Reis¹ (Orientador)

IFPR - Campus Jacarezinho¹
heber.morais@ifpr.edu.br

Resumo

A mineração de textos aplica técnicas para classificar dados e revelar padrões em textos, conectando-se ao Processamento de Linguagem Natural (PLN), que busca ensinar computadores a interpretar a linguagem humana. Este projeto objetivou desenvolver uma ferramenta web com API em Python e Flask para pré-processamento textual que fosse acessível a usuários com diferentes níveis técnicos. A ferramenta permite envio de arquivos completos .txt ou inserção do texto diretamente na página web, realizando transformações como remoção de *stop words*, normalização e *stemming*. Os resultados obtidos demonstram a possibilidade de extração de padrões ou tendências nos textos em linguagem natural, exibindo-os de forma modular e dinâmica. Ainda é possível realizar o download do texto processado por completo. Até essa etapa, a ferramenta demonstrou cumprir o objetivo proposto na facilitação da mineração de texto. Futuras melhorias incluem integração com banco de dados e sistema de usuários.

Palavras-chave: Mineração de Texto, Análise Textual, Python, API, Interface Web.

Introdução

Com o crescimento exponencial da produção de dados textuais provenientes das mais diversas fontes, como redes sociais, artigos científicos, notícias, relatórios empresariais, dentre outros, surge a necessidade de ferramentas capazes de interpretar, organizar e extrair informações relevantes a partir de conteúdos não estruturados (Moraes; Ambrósio, 2007). Nesse cenário, a mineração de textos se consolida como uma área estratégica da Ciência da Computação, com forte conexão ao Processamento de Linguagem Natural (PLN), ramo da inteligência artificial que busca dotar as máquinas da capacidade de compreender e manipular a linguagem humana. Por meio da aplicação de algoritmos e métodos estatísticos, essa técnica permite identificar padrões, classificar dados e revelar informações implícitas em textos, viabilizando a análise inteligente de grandes volumes de informação (Vieira; Lopes, 2010).

A abordagem de análise de domínio por meio da mineração de texto tem ganhado destaque crescente em diversas áreas, inclusive na Ciência da Computação, especialmente quando o objetivo é compreender, explorar e extrair conhecimento de grandes quantidades de dados textuais. Alguns trabalhos indicam que, com o avanço das tecnologias de processamento de dados e o aumento da disponibilidade de informações não estruturadas, torna-se essencial o desenvolvimento de ferramentas capazes de automatizar a análise e a extração de conhecimento (Han; Pei; Kamber, 2012; Reis, 2023). Apesar da existência de ferramentas consolidadas para esse tipo de tarefa, estudos indicam que soluções personalizadas tendem a apresentar melhores resultados em domínios específicos, ao oferecer maior precisão, flexibilidade e adaptabilidade (Souza; Schirru; Alvarenga, 2020; Reis, 2023). Isso justifica o desenvolvimento de novos algoritmos e interfaces que considerem as peculiaridades linguísticas de cada área de conhecimento.

Neste contexto, o presente projeto se propõe a dar os primeiros passos no desenvolvimento de uma API e de uma interface web para análise de domínio baseada em mineração de texto. A proposta visa oferecer uma solução simples, acessível e funcional, tanto para usuários iniciantes quanto para pesquisadores e profissionais de várias áreas, com foco em pré-processamento textual e análise de frequência de termos. Assim, o principal objetivo deste trabalho é implementar uma aplicação que permita o processamento de textos e a extração de padrões linguísticos relevantes.



Metodologia

A metodologia utilizada para a construção de uma API em Python, utilizou o framework Flask, responsável pelo processamento dos textos enviados pelos usuários. Inicialmente, o sistema foi projetado para permitir a entrada de dados por meio do upload de arquivos no formato .txt ou por inserção do texto diretamente na página web, garantindo flexibilidade na utilização da ferramenta. Para atender às necessidades específicas de limpeza e transformação textual, foram implementadas diversas etapas configuráveis, que o usuário pode selecionar e ordenar conforme seu interesse. Conforme Reis (2023), essas etapas incluem: remoção de números, eliminação de caracteres especiais, remoção de acentuações, exclusão de stopwords, conversão de todo o texto para letras minúsculas e aplicação da técnica de stemming para reduzir as palavras às suas raízes.

A linguagem Python foi utilizada em conjunto com bibliotecas específicas voltadas ao processamento textual, como o NLTK, responsável pela identificação e remoção de *stopwords* e pela aplicação do *stemming*; a biblioteca “re”, empregada na utilização de expressões regulares para a filtragem de padrões textuais indesejados; e a biblioteca “unicodedata”, utilizada para a normalização de caracteres e remoção de acentos, garantindo uniformidade ao texto analisado. A API processa o texto seguindo a ordem estabelecida pelo usuário, garantindo modularidade e controle sobre o fluxo das transformações.

Os resultados são retornados de forma segmentada e exibidos dinamicamente na interface web, com recursos que facilitam a visualização e cópia dos textos processados em cada etapa. Complementando essa exibição interativa, a aplicação incorpora funcionalidades analíticas importantes, como a geração de ranking e nuvem de palavras dos termos mais frequentes, que auxiliam na visualização e compreensão dos padrões textuais extraídos. Para melhor representar a lógica do sistema, o fluxograma apresentado na Figura 1 representa o encadeamento modular do processo do sistema de pré-processamento textual, detalhando cada etapa da interação entre usuário, interface gráfica e API.




Figura 1 - Fluxograma do processo de pré-processamento textual (Fonte: os autores).

Resultados e Discussão

Com base na estrutura metodológica descrita, foi possível desenvolver uma aplicação funcional que alia processamento linguístico automatizado a uma interface intuitiva e interativa. A seguir, são apresentados os principais resultados obtidos com a implementação do sistema, destacando-se a forma como a interface gráfica se integra ao funcionamento da API para viabilizar, de maneira acessível e eficiente, o pré-processamento e a análise textual.

Conforme apresentado na Figura 2, a interface gráfica permite ao usuário tanto o upload de arquivos no formato .txt quanto a inserção manual de textos por meio de uma caixa de texto. Após o envio do conteúdo, o usuário pode selecionar e ordenar, de forma personalizada, as transformações linguísticas que deseja aplicar como, remoção de stop words, remover números, aplicar stemming, dentre outros. Essa flexibilidade no encadeamento das etapas contribui diretamente para a adaptação da análise a diferentes objetivos e contextos.



Faça o upload do seu texto aqui:

Arraste um arquivo .txt aqui ou clique para selecionar

A mineração de textos emerge como uma técnica essencial na análise de grandes volumes de dados textuais, permitindo a extração de informações relevantes e a identificação de padrões complexos em dados não estruturados. Este projeto explora algumas das principais etapas e ferramentas disponíveis para a aplicação dessa técnica, destacando sua relevância em áreas como análise de dados, categorização de documentos e interpretação de padrões. A justificativa para este trabalho surge da necessidade de lidar com grandes volumes de dados não estruturados de forma eficaz, em um momento em que o volume de informações geradas por diversos setores, como, pesquisa acadêmica, análise de mercado e processamento de linguagem natural, tem crescido exponencialmente. Os objetivos deste trabalho incluem o desenvolvimento inicial de um algoritmo que, a partir de um conjunto de arquivos de texto, é capaz de realizar o pré-processamento necessário, aplicar algumas técnicas de mineração de texto, como a contagem de

Ordem das Transformações (Clique para
Selecionar e Arraste para Reordenar)

☒ Remover Números

☒ Remover Caracteres Especiais

☒ Remover Acentos

☐ Converter para Minúsculas

☐ Remover Stopwords

☐ Aplicar Stemming

☐ Ranking dos 10 Termos mais Frequentes

☐ Nuvem de Palavras

Processar Texto

Figura 2 - Tela de envio do texto e transformações do sistema desenvolvido (Fonte: os autores).

Como ilustrado na Figura 3, os resultados processados são exibidos de forma segmentada, etapa por etapa, permitindo ao usuário acompanhar as modificações progressivas no conteúdo textual. Neste exemplo, destacam-se a exibição do ranking dos termos mais frequentes e a nuvem de palavras gerada a partir do texto transformado.

Ranking dos 10 Termos mais Frequentes:

cientif: 8
produca: 7
pesquis: 5
sociolog: 4
criteri: 4
cnpq: 4
cap: 4
academ: 3
bolsist: 3
frent: 2

Copiar Texto

Nuvem de Palavras:



Figura 3 - Tela de resultados do sistema (Fonte: os autores).

A aplicação do algoritmo Snowball Stemmer revelou-se particularmente eficaz na redução e unificação de termos com a mesma raiz. Palavras como “organização”, “organizar” e “organizado”, por exemplo, passaram a ser representadas por uma mesma forma base, o que teve impacto direto sobre a composição dos rankings e da nuvem de palavras. Essa padronização dos termos possibilitou uma visualização mais clara dos tópicos predominantes no texto analisado, mesmo por usuários sem formação técnica. Os resultados quantitativos, obtidos por meio do ranking e da nuvem de palavras, evidenciaram os termos de maior frequência em cada amostra textual. Isso não apenas reforça a capacidade analítica da ferramenta, mas também sua utilidade didática, permitindo que estudantes e profissionais compreendam os efeitos de cada transformação aplicada.



Em comparação com outras soluções disponíveis, a aplicação se destaca por sua simplicidade de uso, adaptabilidade ao contexto do usuário e caráter educativo. Ao oferecer total controle sobre as etapas de pré-processamento, a ferramenta torna-se uma aliada valiosa tanto para análises técnicas quanto para o ensino de conceitos fundamentais de Processamento de Linguagem Natural (PLN) e mineração de texto. De forma geral, os resultados obtidos validam os objetivos propostos inicialmente, demonstrando a funcionalidade e aplicabilidade da ferramenta no cenário de análise textual. Para trabalhos futuros, planeja-se a integração com um sistema de banco de dados que permita o cadastro de usuários, armazenamento de consultas anteriores e o uso de filtros semânticos ou classificadores automáticos, ampliando as possibilidades de análise e tornando o sistema ainda mais robusto e inteligente.

A comparação entre textos com e sem a aplicação do Snowball Stemmer evidenciou diferenças significativas na forma como os termos são reduzidos e agrupados. Termos como “organização”, “organizar” e “organizado” foram unificados em uma mesma raiz, impactando diretamente os rankings e a nuvem de palavras. A análise quantitativa, via ranking e nuvem de palavras, permitiu visualizar com clareza os termos mais frequentes em cada amostra, tornando o processo analítico mais acessível também a usuários não técnicos. Comparada a outras ferramentas, a aplicação se sobressai pela simplicidade, adaptabilidade e caráter educativo. Ao oferecer controle total sobre as etapas do pré-processamento e visualização dos efeitos gerados, mostra-se eficaz tanto como solução técnica quanto como recurso didático para experimentações em PLN e mineração de texto. Por fim, os resultados validam os objetivos propostos e abrem caminho para futuras melhorias, como filtros semânticos, integração com banco de dados e uso de classificadores automáticos para análises mais avançadas.

Considerações Finais

O desenvolvimento da aplicação web integrada a uma API para análise textual baseada em mineração de texto e Processamento de Linguagem Natural (PLN) cumpriu com êxito os objetivos propostos. A ferramenta mostrou-se eficaz, acessível e funcional, permitindo aos usuários o envio de arquivos .txt ou entrada manual de texto diretamente na página Web, com flexibilidade para selecionar e ordenar diferentes etapas de pré-processamento, como remoção de stopwords, aplicação de stemming, entre outras. Os testes realizados confirmaram a capacidade do sistema de transformar textos brutos em dados estruturados, destacando padrões linguísticos relevantes por meio de rankings e nuvens de palavras. A visualização modular dos resultados, aliada à interface intuitiva, torna o processo acessível a públicos diversos, incluindo aqueles com pouca familiaridade técnica. O sistema ainda se mostrou adaptável a diferentes domínios e objetivos analíticos, podendo ser facilmente reutilizado com novos arquivos e ajustado conforme a necessidade do usuário.

A ferramenta se destaca pela simplicidade de uso, adaptabilidade e potencial didático, sendo útil tanto para pesquisadores quanto para estudantes e profissionais que desejam explorar ou aplicar técnicas de PLN de forma prática. Além disso, o comportamento da aplicação está alinhado a boas práticas já descritas na literatura, especialmente no uso de técnicas como o stemming para melhorar a eficiência das análises. Como continuidade do trabalho, pode-se realizar a integração de funcionalidades adicionais, como autenticação de usuários, armazenamento de históricos de análise e implementação de filtros semânticos e classificadores automáticos. Essas melhorias visam ampliar o potencial de uso da ferramenta e torná-la ainda mais robusta para aplicações avançadas de análise textual. Em suma, este projeto representa um passo inicial na construção de uma solução acessível e eficaz para pré-processamento e exploração de textos, com potencial de crescimento e aplicação em contextos educacionais, acadêmicos e profissionais.

Referências

- HAN, J.; PEI, J.; KAMBER, M. Data mining: concepts and techniques. 3. ed. Amsterdam: Elsevier, 2012.
- MORAIS, E. A. M.; AMBRÓSIO, A. P. L. Mineração de textos. Goiânia: Instituto de Informática, Universidade Federal de Goiás, 2007. Relatório Técnico – INF_005/07.
- REIS, Elismar Vicente dos. Proposta de metodologia para abordagem terminológica da análise de domínio baseada em mineração de texto: uma aplicação na ciência da informação. Universidade Estadual Paulista (Unesp), 2023.
- SOUZA, R. S.; SCHIRRU, R. P.; ALVARENGA, R. S. Análise de texto e mineração de dados na prática. 2. ed. Belo Horizonte: Editora UFMG, 2020.
- VIEIRA, R.; LOPES, L. Processamento de linguagem natural e o tratamento computacional de linguagens científicas. In: PERNA, C. L.; DELGADO, H. K.; FINATTO, M. J. (orgs.). Linguagens especializadas em corpora: modos de dizer e interfaces de pesquisa. Porto Alegre: EDIPUCRS, 2010. p. 183–201.