



CRIAÇÃO INICIAL DE ALGORITMOS PARA ANÁLISE DE DOMÍNIO BASEADA EM MINERAÇÃO DE TEXTO EM PYTHON

Matheus Mendes Lourenço

*Instituto Federal do Paraná Campus Jacarezinho, Curso Técnico em Informática,
matheusmendeslourenco@gmail.com*

Lincoln Maggini Mauro

*Instituto Federal do Paraná Campus Jacarezinho, Curso Técnico em Informática,
lincoln.maggini@gmail.com*

Héber Renato Fadel de Moraes

Instituto Federal do Paraná Campus Jacarezinho, heber.morais@ifpr.edu.br

Elismar Vicente dos Reis

Instituto Federal do Paraná Campus Jacarezinho, elismar.reis@ifpr.edu.br

RESUMO

A mineração de textos emerge como uma técnica essencial na análise de grandes volumes de dados textuais, permitindo a extração de informações relevantes e a identificação de padrões complexos em dados não estruturados. Este projeto explora algumas das principais etapas e ferramentas disponíveis para a aplicação dessa técnica, destacando sua relevância em áreas como análise de dados, categorização de documentos e interpretação de padrões. A justificativa para este trabalho surge da necessidade de lidar com grandes volumes de dados não estruturados de forma eficaz, em um momento em que o volume de informações geradas por diversos setores, como, pesquisa acadêmica, análise de mercado e processamento de linguagem natural, tem crescido exponencialmente. Os objetivos deste trabalho incluem o desenvolvimento inicial de um algoritmo que, a partir de um conjunto de arquivos de texto, é capaz de realizar o pré-processamento necessário, aplicar algumas técnicas de mineração de texto, como a contagem de frequências de termos e a geração de nuvens de palavras, a fim de proporcionar visualizações gráficas que facilitem a análise dos resultados. Para isso, foram utilizadas bibliotecas da linguagem de programação Python, como o NLTK (Natural Language Toolkit), que fornece recursos avançados de processamento de linguagem natural, a biblioteca de expressões regulares (re), o Matplotlib, usado para criar visualizações gráficas, e o Unicodedata, que permite normalizar textos eliminando caracteres especiais. O



algoritmo desenvolvido processa arquivos de texto (.txt), realizando pré-processamento por meio da remoção de números, caracteres especiais, acentuações e palavras comuns, conhecidas também como stopwords, além da aplicação do método Snowball Stemmer, uma técnica que reduz palavras ao seu radical linguístico, facilitando assim a análise de variações linguísticas. Como resultado, foi possível gerar representações gráficas, como nuvens de palavras e rankings de frequência de termos com o método Snowball Stemmer aplicado ou não, que auxiliam na interpretação e análise de dados.

Palavras-chave: Mineração de textos; Python; Análise de dados.

INTRODUÇÃO

A análise de domínio baseada em mineração de texto tem se tornado uma abordagem cada vez mais relevante no contexto da Ciência da Computação, especialmente quando se busca compreender, explorar e extrair informações valiosas a partir de grandes volumes de dados textuais. Estudos destacam que o avanço das tecnologias de processamento de dados, aliado à crescente disponibilidade de informações não estruturadas, exige o desenvolvimento de ferramentas que automatizam a análise e a extração de conhecimento (Han, Pei & Kamber, 2012). Nesse cenário, a mineração de texto se destaca como uma técnica fundamental para a identificação de padrões, tópicos e relacionamentos subjacentes em conjuntos de dados textuais, sendo amplamente utilizada em contextos acadêmicos e industriais (Pedroso, Lima & Neto, 2017; Souza, Schirru & Alvarenga, 2020).

A mineração de texto envolve a aplicação de algoritmos que permitem a extração de informações úteis de textos não estruturados. A análise de domínio, por sua vez, foca na identificação e extração de conhecimento específico de um determinado campo de aplicação, sendo essencial para áreas como a categorização de documentos, análise de sentimentos e recomendações de produtos (Safdari et al., 2021; Pedroso, Lima & Neto, 2017). Embora ferramentas prontas para mineração de texto estejam amplamente disponíveis, estudos apontam que o desenvolvimento de algoritmos personalizados pode oferecer vantagens significativas, como maior precisão ao atender às necessidades de domínios



específicos e maior flexibilidade para ajustes finos em processos de pré-processamento e análise dos dados (Rezende, 2005; Souza, Schirru & Alvarenga, 2020).

Este projeto propõe a criação inicial de algoritmos para a análise de domínio baseada em mineração de texto utilizando a linguagem de programação Python. O foco está na implementação de um sistema capaz de processar e analisar textos de forma eficiente, utilizando bibliotecas como NLTK, re, unicodedata, os e matplotlib. A escolha dessas ferramentas visa permitir a realização de tarefas essenciais no processamento de texto, como a limpeza de dados, remoção de “*stopwords*”, normalização e a análise de frequência de termos. A utilização do *Snowball Stemmer*, uma técnica que reduz as palavras ao seu radical, será aplicada como parte da análise linguística, facilitando a compreensão das variações linguísticas dentro de um domínio específico.

A motivação para este projeto surge da necessidade de lidar com grandes volumes de dados não estruturados de forma eficaz, em um momento em que o volume de informações geradas por diversas fontes tem crescido exponencialmente. Embora ferramentas prontas para mineração de texto já estejam disponíveis, elas frequentemente não são adaptáveis o suficiente para a análise específica de determinados domínios, o que pode resultar em soluções menos precisas e eficientes. Assim, a proposta deste projeto é o desenvolvimento de um algoritmo inicial que não só automatize o processo de mineração de texto, mas também ofereça flexibilidade e customização para atender a diferentes necessidades, permitindo a adaptação e expansão conforme o domínio de aplicação se desenvolve.

O principal objetivo deste trabalho é desenvolver um algoritmo que, a partir de um conjunto de arquivos de texto, seja capaz de realizar o pré-processamento necessário, aplicar técnicas de mineração de texto, como a contagem de frequências de termos e a geração de nuvens de palavras, a fim de proporcionar visualizações gráficas que facilitem a análise dos resultados. Além disso, o sistema é projetado para possibilitar uma compreensão mais profunda do domínio de análise, identificando as principais características dos textos, como a frequência de



termos específicos e os padrões que emergem a partir do uso de algoritmos de stemming e técnicas de classificação.

Nos próximos tópicos, serão detalhados os materiais e métodos empregados no desenvolvimento do algoritmo proposto, bem como os resultados obtidos durante a execução do algoritmo, destacando a aplicação do método “Snowball Stemmer” e outras ferramentas para a análise de dados textuais.

MATERIAIS E MÉTODOS

A metodologia deste projeto foi desenvolvida com o objetivo de criar um processo eficiente para o processamento e análise de textos utilizando a linguagem de programação Python. O foco esteve no uso de bibliotecas especializadas, que otimizam e simplificam as etapas de limpeza, transformação e visualização de dados textuais, além de fornecer suporte à manipulação de arquivos e diretórios.

Entre as principais ferramentas empregadas, destaca-se o **NLTK (Natural Language Toolkit)**, amplamente utilizado no campo do processamento de linguagem natural, que oferece recursos como tokenização, stemming e lematização. Para etapas de limpeza e pré-processamento, a biblioteca **re** desempenhou um papel essencial ao permitir a manipulação de expressões regulares, facilitando a remoção de padrões indesejados no texto. A biblioteca **unicodedata** também foi utilizada para normalizar os textos, removendo caracteres especiais e garantindo maior uniformidade dos dados.


Além dessas, a biblioteca **os** foi integrada ao projeto para gerenciar eficientemente os arquivos e diretórios do sistema operacional. Essa ferramenta permitiu organizar e acessar os arquivos de texto na pasta específica destinada ao processamento, garantindo que as etapas do algoritmo fossem executadas de maneira estruturada. Para a visualização dos resultados, utilizou-se a **Matplotlib**, uma biblioteca robusta para a criação de gráficos, que viabilizou a geração de representações visuais claras e intuitivas, como gráficos de frequência e nuvens de palavras.

O algoritmo foi estruturado para cobrir desde a leitura inicial dos arquivos até



a visualização final, com cada etapa detalhadamente planejada. O fluxo do processo, juntamente com um fluxograma explicativo, será apresentado a seguir na Figura 1, destacando como as ferramentas foram aplicadas e os resultados obtidos em cada fase do processamento.

Figura 1 - Fluxograma Mineração de texto em python



Fonte: Adaptada de Reis (2023)

O algoritmo descrito tem como objetivo processar arquivos de texto (.txt) armazenados em uma pasta específica denominada “ArquivosTXT”. A primeira etapa do processo é a limpeza do texto, um passo crucial para a mineração de dados. Essa etapa utiliza expressões regulares para identificar e remover elementos indesejados, como números, caracteres especiais, acentos e diferenças de capitalização, garantindo que todas as palavras sejam convertidas para letras minúsculas.

A remoção de números é realizada por meio de um padrão específico que identifica dígitos individuais ou sequências numéricas consecutivas. Essas sequências são substituídas por uma string vazia, resultando em uma versão limpa



da palavra, sem qualquer elemento numérico. De forma similar, a remoção de caracteres especiais utiliza a biblioteca “re” para identificar símbolos e pontuações que não sejam letras, números ou espaços em branco. Esses caracteres são eliminados, deixando o texto exclusivamente composto por caracteres alfanuméricos.

A etapa seguinte é a remoção de acentos, implementada com a biblioteca unicodedata. O algoritmo decompõe cada palavra em seus caracteres de base e em seus acentos, tratando-os como entidades separadas. Em seguida, os acentos são identificados por sua categoria Unicode e removidos, resultando em palavras que preservam apenas os caracteres essenciais. Essa abordagem garante uma maior uniformidade no processamento linguístico.

Após a limpeza estrutural, o texto é convertido inteiramente para letras minúsculas, padronizando a capitalização e facilitando comparações subsequentes. O texto é então segmentado em palavras individuais, transformando a string original em uma lista manipulável. Para refinar ainda mais os dados, o algoritmo remove as palavras comuns, conhecidas como “*stopwords*”. Esse processo percorre a lista de palavras e elimina aquelas consideradas irrelevantes, como artigos, preposições e conjunções, preservando apenas os termos mais significativos.

O *Snowball Stemmer* é então aplicado para reduzir as palavras às suas raízes. Essa técnica é particularmente útil em análises linguísticas, pois minimiza variações de palavras causadas por pluralização, tempos verbais e outros fatores gramaticais. Embora o stemmer não seja utilizado para gerar a nuvem de palavras, ele permite observar o impacto de cada etapa ao longo do processo, exibindo os resultados intermediários no terminal.

A visualização dos resultados segue um fluxo sequencial: o texto original é exibido e, em seguida, os dados processados em cada etapa, incluindo a remoção de números, caracteres especiais, acentos, conversão para minúsculas, separação em palavras, remoção de *stopwords* e aplicação do *Snowball Stemmer*. Para consolidar os resultados, o algoritmo adota a técnica de “*Bag of Words*”, que transforma o texto em um conjunto de palavras, contabilizando a frequência de cada termo sem considerar sua ordem. Esses termos são convertidos em objetos da



classe "termo" para serem utilizados em operações como contagem de co-ocorrências e agrupamento por frequência.

Os termos são então organizados em um ranking decrescente, indicando a quantidade de ocorrências de cada um no texto. Por fim, é gerada uma nuvem de palavras, destacando visualmente os termos mais frequentes com tamanhos proporcionais à sua relevância. Essa visualização é criada tanto com quanto sem a aplicação do *Snowball Stemmer*, permitindo comparações entre as versões.

Todo o processo se beneficia de bibliotecas robustas como NLTK, re, unicodedata e Matplotlib, que fornecem ferramentas essenciais para a execução de tarefas complexas. Técnicas como remoção de números, caracteres especiais e acentos, combinadas com o uso do stemmer, garantem um alto nível de limpeza e organização do texto. A criação de nuvens de palavras e rankings de frequência oferece uma visão clara e intuitiva dos dados analisados, permitindo insights profundos sobre a composição textual e a relevância dos termos.

Em resumo, o processamento automatizado de textos descrito representa uma abordagem estruturada e eficiente para a análise linguística e mineração de dados textuais. As etapas cuidadosamente implementadas, desde a limpeza inicial até a visualização final em nuvens de palavras e rankings, demonstram como ferramentas computacionais podem extrair informações relevantes de grandes volumes de dados. O uso combinado de bibliotecas especializadas e técnicas avançadas, como o *Snowball Stemmer*, não apenas organiza e simplifica os textos, mas também possibilita uma análise mais precisa e significativa. Esse processo, ao transformar textos brutos em dados úteis, destaca seu potencial para aplicações em áreas como pesquisa acadêmica, análise de mercado e processamento de linguagem natural.

ANÁLISE E DISCUSSÃO DOS RESULTADOS

A apresentação dos resultados permite avaliar o desempenho do algoritmo desenvolvido na análise de textos em formato .txt. Durante o processamento, diversas etapas de limpeza e transformação foram aplicadas ao arquivo .txt. O



V JORNADA DE ESTUDOS EM TECNOLOGIA DA INFORMAÇÃO

TENDÊNCIAS E PERSPECTIVAS EM TECNOLOGIA DA INFORMAÇÃO
03 A 06 DE DEZEMBRO 2024

objetivo foi identificar padrões textuais e extrair informações relevantes. A seguir, são mostradas as saídas geradas pelo algoritmo, incluindo exemplos com e sem a aplicação do *Snowball Stemmer*, destacando o impacto de cada etapa na qualidade da análise. Como entrada foi utilizada uma parte do próprio resumo deste artigo para ser exemplificada as saídas do algoritmo, de acordo com o Fluxograma apresentado na Figura 1, assim, as Figuras 2 e 3 apresentam as saídas obtidas após a execução do algoritmo, sem e com a aplicação do *Snowball Stemmer*.



V JORNADA DE ESTUDOS EM TECNOLOGIA DA INFORMAÇÃO

TENDÊNCIAS E PERSPECTIVAS EM TECNOLOGIA DA INFORMAÇÃO
03 A 06 DE DEZEMBRO 2024

Figura 2 - Saída dos processamentos de texto realizada, parte 01.

Texto Original

A mineração de textos emerge como uma técnica essencial na análise de grandes volumes de dados textuais, permitindo a extração de informações relevantes e a identificação de padrões complexos em dados não estruturados. Este projeto explora algumas das principais etapas e ferramentas disponíveis para a aplicação dessa técnica, destacando sua relevância em áreas como análise de dados, categorização de documentos e interpretação de padrões.

Texto sem Números

A mineração de textos emerge como uma técnica essencial na análise de grandes volumes de dados textuais, permitindo a extração de informações relevantes e a identificação de padrões complexos em dados não estruturados. Este projeto explora algumas das principais etapas e ferramentas disponíveis para a aplicação dessa técnica, destacando sua relevância em áreas como análise de dados, categorização de documentos e interpretação de padrões.

Texto sem Caracteres Especiais

A mineração de textos emerge como uma técnica essencial na análise de grandes volumes de dados textuais permitindo a extração de informações relevantes e a identificação de padrões complexos em dados não estruturados Este projeto explora algumas das principais etapas e ferramentas disponíveis para a aplicação dessa técnica destacando sua relevância em áreas como análise de dados categorização de documentos e interpretação de padrões

Texto sem Acentos

A mineracao de textos emerge como uma tecnica essencial na analise de grandes volumes de dados textuais permitindo a extracao de informacoes relevantes e a identificacao de padroes complexos em dados nao estruturados Este projeto explora algumas das principais etapas e ferramentas disponiveis para a aplicacao dessa tecnica destacando sua relevancia em areas como analise de dados categorizacao de documentos e interpretacao de padroes

Texto em Letras Minúsculas

a mineracao de textos emerge como uma tecnica essencial na analise de grandes volumes de dados textuais permitindo a extracao de informacoes relevantes e a identificacao de padroes complexos em dados nao estruturados este projeto explora algumas das principais etapas e ferramentas disponiveis para a aplicacao dessa tecnica destacando sua relevancia em areas como analise de dados categorizacao de documentos e interpretacao de padroes

Texto sem Stopwords

mineracao textos emerge tecnica essencial analise grandes volumes dados textuais permitindo extracao informacoes relevantes identificacao padroes complexos dados nao estruturados projeto explora algumas principais etapas ferramentas disponiveis aplicacao dessa tecnica destacando relevancia areas analise dados categorizacao documentos interpretacao padroes

Texto com Snowball Stemmer

mineraca text emerg tecnic essencial analis grand volum dad textu permit extraca informaco relev identificaca padro complex dad nao estrutur projet explor algum princip etap ferrament disponiv aplicaca dess tecnic destac relevanc are analis dad categorizaca document interpreta padro

Ranking das 10 Palavras mais Frequentes sem Snowball Stemmer

```
Texto Original: 1 Resumo.txt
Ranking das 10 palavras mais frequentes:
1. dados: 3
2. analise: 2
3. padroes: 2
4. tecnica: 2
5. algumas: 1
6. aplicacao: 1
7. areas: 1
8. categorizacao: 1
9. complexos: 1
10. dessa: 1
```



V JORNADA DE ESTUDOS EM TECNOLOGIA DA INFORMAÇÃO

TENDÊNCIAS E PERSPECTIVAS EM TECNOLOGIA DA INFORMAÇÃO
03 A 06 DE DEZEMBRO 2024

Figura 3 - Saída dos processamentos de texto realizada, parte 02.



Fonte: Desenvolvido pelos autores (2024);

O algoritmo desenvolvido é flexível e pode ser utilizado para processar outros textos escolhidos pelo usuário. Basta adicionar os arquivos .txt desejados na pasta designada para processamento, permitindo uma análise adaptada a diferentes contextos e objetivos. Essa versatilidade torna a ferramenta útil para aplicações variadas, como classificação de documentos, identificação de tendências textuais e apoio à tomada de decisões baseada em dados textuais.

CONSIDERAÇÕES FINAIS

Como conclusão, os objetivos propostos pelo projeto foram alcançados, com a implementação de um algoritmo inicial para análise de domínio baseada em mineração de texto que lê arquivos .txt de uma pasta específica, realiza o processamento textual por meio de filtragem e criação de listas de palavras, e exibe os resultados em forma de ranking e nuvem de palavras, incluindo a aplicação do



método *snowball stemmer* para análise linguística.

Os resultados obtidos com a implementação do algoritmo demonstram benefícios claros para o usuário, como a facilidade de organizar grandes volumes de texto, identificar padrões por meio do *ranking* de palavras e visualizar as informações de forma intuitiva com a nuvem de palavras. A aplicação do *Snowball Stemmer* acrescenta um nível adicional de análise, reduzindo palavras às suas raízes e permitindo interpretações mais precisas. Esses ganhos tornam a ferramenta uma solução prática e eficiente para a análise de dados textuais em diversos domínios.

Para aprimorar o projeto, planeja-se o desenvolvimento de uma interface *web* que permitirá ao usuário incluir arquivos, configurar formatos de saída e acompanhar visualmente cada etapa do processo de mineração de textos. Essa plataforma online poderá consolidar os resultados das diferentes etapas de processamento, oferecendo um resumo geral de todos os arquivos analisados, com representações gráficas como nuvens de palavras e *rankings*. Além disso, o aprimoramento do sistema inclui a expansão de funcionalidades, como a aplicação de outras técnicas de mineração de texto e maior flexibilidade na configuração dos parâmetros. Esse avanço facilitará o acesso e a utilização do sistema por usuários com diferentes níveis de familiaridade com análise de dados textuais, ampliando a aplicabilidade do projeto em cenários reais.

REFERÊNCIAS

HAN, J.; PEI, J.; KAMBER, M. *Data mining: concepts and techniques*. 3. ed. Amsterdam: Elsevier, 2012.

PEDROSO, J. B.; LIMA, J. S.; NETO, A. M. *Análise de dados e mineração de texto: uma abordagem aplicada*. São Paulo: Editora Ciência e Tecnologia, 2017.

REIS, Elismar Vicente dos. *Proposta de metodologia para abordagem terminológica da análise de domínio baseada em mineração de texto: uma aplicação na Ciência da Informação*. 2023. 151 p. Tese (Doutorado) – Universidade Estadual Paulista



V JORNADA DE ESTUDOS EM TECNOLOGIA DA INFORMAÇÃO

TENDÊNCIAS E PERSPECTIVAS EM TECNOLOGIA DA INFORMAÇÃO
03 A 06 DE DEZEMBRO 2024

(UNESP), Marília, 2023.

SAFDARI, S.; DELDAR, M.; KHOSRAVI, A. et al. *Text mining for healthcare applications: challenges and opportunities*. *Journal of Medical Informatics*, v. 72, p. 85-92, 2021.

SOUZA, R. S.; SCHIRRU, R. P.; ALVARENGA, R. S. *Análise de texto e mineração de dados na prática*. 2. ed. Belo Horizonte: Editora UFMG, 2020.