



SISTEMA INTEGRADO A UMA INTERFACE WEB PARA PRÉ-PROCESSAMENTO TEXTUAL: L&M PRÉ-PROCESSAMENTO TEXTUAL

Matheus Mendes Lourenço

*Instituto Federal do Paraná Campus Jacarezinho, Curso Técnico em Informática,
matheusmendeslourenco@gmail.com*

Lincoln Maggini Mauro

*Instituto Federal do Paraná Campus Jacarezinho, Curso Técnico em Informática,
lincoln.maggini@gmail.com*

Héber Renato Fadel de Moraes

Instituto Federal do Paraná Campus Jacarezinho, heber.morais@ifpr.edu.br

Elismar Vicente dos Reis

Instituto Federal do Paraná Campus Jacarezinho, elismar.reis@ifpr.edu.br

RESUMO

Diante do crescimento contínuo da produção de textos em ambientes digitais torna-se necessário ferramentas capazes de organizar e tratar grandes volumes de informação textual. O pré-processamento textual constitui etapa fundamental desse fluxo, ao eliminar ruídos e padronizar elementos linguísticos para análises subsequentes. Entretanto, muitas das soluções disponíveis demandam conhecimentos técnicos avançados, o que limita seu uso por estudantes e profissionais sem experiência na área. Diante desse cenário, este trabalho apresenta o “L&M Pré-Processamento Textual”, uma aplicação integrada a uma interface *web* desenvolvida para tornar acessíveis técnicas de limpeza e transformação de texto de maneira simples, interativa e intuitiva. O sistema permite ao usuário inserir textos manualmente ou por *upload* de arquivo, selecionar e ordenar etapas de pré-processamento e visualizar, de forma imediata, os resultados de cada transformação. A implementação adotou *Flask* para a *API* e tecnologias *web* (*HTML*, *CSS* e *JavaScript*) no *front-end*, assegurando comunicação eficiente entre servidor e interface. Foram utilizadas bibliotecas consolidadas para remoção de *stopwords*, *stemming*, normalização e exclusão de caracteres indesejados, além de recursos para geração automática de estatísticas e gráficos de frequência. Adicionalmente, implementou-se um banco de dados que possibilita cadastro e autenticação de usuários, com armazenamento e consulta do histórico de processamentos. Os testes demonstraram que o sistema opera de forma estável e responsiva em textos de distintos tamanhos, oferecendo autonomia ao usuário e



facilitando o aprendizado das técnicas de pré-processamento textual. Conclui-se que o “L&M Pré-processamento Textual” representa uma ferramenta prática, acessível para análise e mineração de textos em ambientes web, ao conciliar eficiência, usabilidade e potencial para expansão futura.

Palavras-chave: Pré-processamento Textual; Interface Web; Mineração de Texto; API; Análise Textual.

1 INTRODUÇÃO

O avanço das tecnologias de Processamento de Linguagem Natural (PLN) e de Mineração de Textos tem transformado profundamente as formas de extração, interpretação e utilização da informação em diversos contextos, que vão desde a pesquisa científica até o ambiente corporativo. O volume crescente de dados textuais gerados diariamente, provenientes de redes sociais, artigos acadêmicos, documentos empresariais e publicações jornalísticas torna indispensável o desenvolvimento de ferramentas capazes de lidar com informações não estruturadas, permitindo identificar padrões, tendências e relações linguísticas relevantes (Han; Pei; Tong, 2022; Souza; Schirru; Alvarenga, 2024). Aranha e Passos (2006, p. 3) destacam que “o crescimento do armazenamento de dados não estruturados, devido ao avanço da mídia digital, propiciou o desenvolvimento das técnicas de mineração de textos”, reforçando a necessidade de sistemas capazes de estruturar esses dados para análise.

Nesse cenário, técnicas de análise de texto têm ganhado protagonismo em áreas como saúde, educação e opinião pública, impulsionadas pela necessidade de interpretar grandes quantidades de dados em formato textual (Pezzini, 2017). A mineração de textos consolida-se, assim, como uma das principais vertentes da Ciência da Computação, ao aplicar métodos estatísticos e linguísticos voltados à extração de conhecimento a partir de documentos de texto. De modo complementar, o PLN busca dotar os sistemas computacionais da capacidade de compreender e manipular a linguagem humana, aproximando a comunicação entre humanos e



máquinas e possibilitando aplicações como análise de sentimentos, categorização de documentos e extração de informações específicas (Reis, 2023).

Essas potencialidades tornam indispensável o desenvolvimento de sistemas capazes de realizar, de forma automatizada e flexível, processos como normalização, limpeza e transformação linguística de dados textuais. Contudo, apesar dos avanços teóricos, a aplicação prática dessas técnicas ainda exige conhecimento técnico em programação e carece de interfaces acessíveis e intuitivas, que ofereçam autonomia ao usuário no controle do fluxo de pré-processamento. Diante dessa lacuna, este trabalho propõe o desenvolvimento de um sistema *web* para análise textual, que possibilita ao usuário escolher e ordenar as etapas de pré-processamento, como remoção de *stopwords*, *stemming* e normalização, além de visualizar dinamicamente os resultados e gerenciar o histórico de análises realizadas.

Assim, o objetivo deste artigo é apresentar a versão final do sistema desenvolvido, destacando sua arquitetura baseada em *API*, interface *web* e banco de dados, bem como suas funcionalidades de análise e persistência de dados, evidenciando sua contribuição para a autonomia e a flexibilidade analítica na área de mineração textual.

Nos tópicos seguintes, são apresentados os materiais, métodos e tecnologias empregados na implementação do sistema, seguidos da análise dos resultados obtidos e da discussão de suas funcionalidades.

2 MATERIAIS E MÉTODOS


A metodologia adotada neste projeto teve como objetivo desenvolver uma ferramenta completa de pré-processamento e análise textual em ambiente *web*, integrando um algoritmo modular em *Python* a uma interface interativa e responsiva. O sistema foi projetado para que o usuário pudesse selecionar, personalizar e salvar diferentes etapas de processamento textual.



O desenvolvimento do sistema seguiu o modelo de prototipagem incremental, que consiste na criação de versões sucessivas e funcionais do produto, avaliadas e aprimoradas conforme os resultados obtidos e o *feedback* dos testes. Inicialmente, foram elaborados protótipos dos algoritmos, seguidos pela implementação da *API* e da interface *web*, culminando na integração com o banco de dados.

Para representar a lógica do sistema, foram elaborados diagramas que descrevem suas principais interações. O Diagrama de Caso de Uso (Figura 1) apresenta a relação entre os atores (usuário e usuário logado) e as funcionalidades centrais, como processar texto, realizar *login*, realizar *download*, salvar processamento, dentre outros.

Figura 1 – Diagrama de caso de uso




Fonte: Desenvolvido pelos autores (2025).

A modelagem do banco de dados foi elaborada por meio de um Diagrama Entidade-Relacionamento (DER) (Figura 2), composto pelas entidades usuário, texto e etapa. O relacionamento entre essas entidades permite armazenar as informações de cada processamento, vinculadas ao respectivo usuário. O usuário possui um ou



mais processos; cada processo contém várias etapas (com tipo, ordem e resultado textual).

Figura 2 – Diagrama entidade-relacionamento (DER)



Fonte: Desenvolvido pelos autores (2025).

A *API* do sistema foi desenvolvida em linguagem *Python*, amplamente empregada na área de Processamento de Linguagem Natural (PLN) devido ao suporte de bibliotecas consolidadas. Entre elas, destaca-se o *NLTK* (*Natural Language Toolkit*), utilizado na remoção de *stopwords* e na aplicação de *stemming*, técnica que reduz as palavras às suas raízes, promovendo uniformidade lexical. A biblioteca *re* foi empregada na utilização de expressões regulares para filtragem e exclusão de padrões indesejados, como números, pontuações e caracteres especiais. Já a biblioteca *unicodedata* foi utilizada na normalização de caracteres e remoção de acentuações, garantindo consistência textual.

O framework *Flask* foi selecionado para a construção da *API* em razão de sua leveza e modularidade, possibilitando a criação de rotas específicas para *upload* de textos, execução de etapas de pré-processamento, exportação de resultados e gerenciamento de usuários autenticados. Essa estrutura assegura uma comunicação eficiente entre o *backend* e o *frontend*, permitindo que cada solicitação do usuário seja processada de forma independente e segura.



No lado do cliente, o sistema foi desenvolvido com *HTML5*, *CSS3* e *JavaScript*, integrando bibliotecas e *frameworks* que aprimoram a experiência do usuário. O *Bootstrap* foi empregado para garantir responsividade e padronização visual da interface, enquanto o *Petite-Vue* proporcionou reatividade leve e eficiente, atualizando dinamicamente os resultados conforme o processamento é executado. A biblioteca *Sortable.js* foi incorporada para permitir que o usuário organize as etapas do algoritmo de forma intuitiva, utilizando o recurso de arrastar e soltar (*drag and drop*). Além disso, a *Chart.js* foi utilizada para a geração de gráficos interativos, representando visualmente estatísticas textuais, como o *ranking* de frequência de termos. Ao final de cada operação, são geradas estatísticas automáticas, como número total de palavras, contagem de caracteres (com e sem espaço) e *ranking* de frequência de termos, exibidas no painel de resultados.

O algoritmo de pré-processamento textual foi desenvolvido para processar tanto textos digitados manualmente quanto arquivos enviados pelo usuário. Após a inserção dos dados, o algoritmo executa as etapas selecionadas conforme a ordem definida na interface. Cada etapa é implementada como uma função independente dentro da *API*, o que assegura modularidade e facilita futuras expansões do sistema.

Os resultados intermediários e finais podem ser visualizados, copiados, baixados individualmente ou exportados em formato *.txt* ou *PDF*. Usuários autenticados têm ainda a possibilidade de salvar seus processamentos no banco de dados, acessando posteriormente um histórico que permite renomear, excluir ou reabrir análises anteriores.

Em síntese, o conjunto de técnicas, ferramentas e diagramas empregados neste projeto possibilitou a criação de uma aplicação *web* escalável e de fácil utilização, que combina métodos de pré-processamento textual com visualização interativa e persistência de dados. O resultado é um sistema *web* que une teoria e prática, aplicando conceitos de mineração de texto e PLN em uma plataforma acessível e adaptável a diferentes contextos analíticos.




3 ANÁLISE E DISCUSSÃO DOS RESULTADOS

Com base na metodologia apresentada, foi possível desenvolver uma aplicação funcional que integra o processamento linguístico automatizado a uma interface gráfica intuitiva e interativa, permitindo ao usuário configurar, executar e visualizar o processamento de textos conforme suas necessidades específicas.

A tela inicial e a tela de *login* (Figura 3) apresentam: acessar a tela do sistema de processamento, voltada à experimentação das funcionalidades, sem a possibilidade de salvar os processos no banco de dados. A tela de login ou cadastro possibilitam que novos usuários criem uma conta com informações básicas.

Figura 3 – Página inicial do sistema e tela de *login* e cadastro



Fonte: Desenvolvido pelos autores (2025).

Após o *login*, o usuário é direcionado para sua área pessoal, onde pode visualizar e editar seus dados cadastrais e acessar o sistema com todas as funcionalidades disponíveis.



VI JORNADA DE ESTUDOS EM TECNOLOGIA DA INFORMAÇÃO

DESAFIOS E OPORTUNIDADES NA ERA DIGITAL

17 A 19 DE NOVEMBRO 2025

Na página do sistema e seleção de etapas do processamento (Figura 4), o usuário pode inserir um texto manualmente ou realizar o *upload* de um arquivo no formato *.txt*, além de escolher e ordenar livremente as etapas de pré-processamento, como remoção de números, caracteres especiais, acentuação, *stopwords* e aplicação do *snowball stemmer*. A interface permite também a reordenação dinâmica das etapas. Essa flexibilidade torna o sistema personalizável, permitindo observar o impacto de cada transformação textual em tempo real.

Figura 4 – Página do sistema e seleção de etapas do processamento

Faça o upload do seu texto aqui:

Arraste um arquivo .txt aqui ou clique para selecionar

1 - O Pré-processamento textual é uma etapa crucial em qualquer projeto de Mineração de Textos (Text Mining) ou Processamento de Linguagem Natural (PLN). Ele transforma dados de texto brutos, que são frequentemente caóticos e cheios de ruídos, em um formato limpo e estruturado que os algoritmos de aprendizado de máquina podem processar de forma eficiente. Sem essa etapa, a qualidade da análise seria comprometida, levando a resultados imprecisos e insights enganosos.

Etapas Disponíveis

+ Remover Números

+ Remover Caracteres Especiais

+ Remover Acentos

+ Converter para Minúsculas

+ Remover Stopwords

+ Aplicar Stemming

+ Ranking de palavras e gráficos

Ordem de Execução (Clique e arraste)

Remover Números

Remover Caracteres Especiais

Converter para Minúsculas

Aplicar Stemming

Ranking de palavras e gráficos

Máx. Palavras: 10
Gráfico: Nenhum

Usar Exemplo

Processar

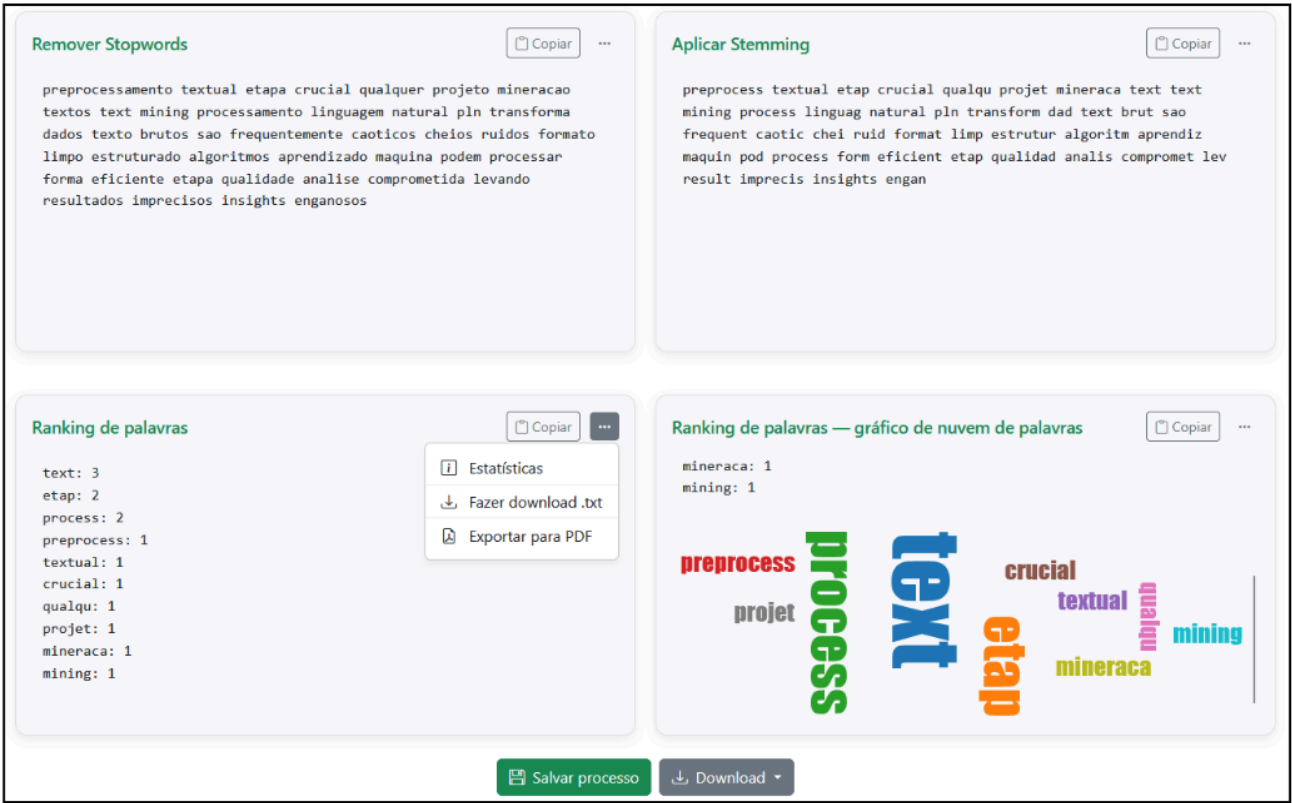
Fonte: Desenvolvido pelos autores (2025).

Na página do sistema, na seção de resultados de um processamento (Figura 5), são apresentados, logo após o usuário processar o texto, todas as etapas selecionadas, organizadas na sequência definida. Além disso, exibe-se o resultado final do processo, acompanhado do texto original, para facilitar a comparação entre



ambos. O usuário pode realizar o *download* de cada etapa ou o processo por completo e também copiar o texto sem precisar fazer *login*, mas precisa estar logado para salvar o processo. Além disso, é interessante ressaltar que o sistema pode exibir visualizações gráficas do processamento caso o usuário deseje. Por exemplo, podem ser gerados gráficos de nuvens de palavras e gráficos de barras, que auxiliam na análise dos dados processados, organizados com base no *ranking* da frequência de palavras.

Figura 5 – Página do sistema e resultados de um processamento



Fonte: Desenvolvido pelos autores (2025).

Durante os testes realizados, observou-se que a aplicação manteve desempenho estável mesmo com textos extensos, resultado da modularização da *API* em *Python/Flask*. O processamento sequencial e independente de cada etapa assegurou rápida renderização dos resultados. A comunicação entre a *API* e a



interface garantiu a consistência dos dados e a atualização das visualizações, proporcionando uma experiência de uso fluida e eficiente.

Em comparação com soluções já existentes, o sistema desenvolvido apresenta uma abordagem mais flexível e interativa. Ferramentas como o *Sobek Mining* (REATEGUI et al., 2011), embora executem tarefas de mineração textual, operam com uma sequência fixa de etapas e oferecem ao usuário resultados essencialmente estáticos, orientados à aplicação direta dos métodos já definidos na ferramenta. Esse tipo de estrutura, apesar de funcional para análises pontuais, reduz a possibilidade de adaptação do fluxo às necessidades específicas de cada usuário. Já o sistema proposto concede autonomia ao permitir a escolha e reorganização da ordem das etapas, possibilitando observar o impacto de cada transformação no texto processado. Além disso, enquanto o *Sobek Mining* não permite ajustar o *pipeline* nem visualizar resultados intermediários de forma dinâmica, o sistema desenvolvido torna essas etapas transparentes, permitindo maior experimentação. Como desvantagem, o sistema proposto ainda não abrange a variedade de técnicas de mineração textual presentes no *Sobek Mining*, que inclui métodos mais avançados e recursos adicionais, entretanto, sua flexibilidade, interatividade e foco na personalização representam vantagens significativas para usuários que desejam maior controle sobre o pré-processamento textual.

Além disso, a integração de recursos como nuvem de palavras dinâmica, rankings interativos e histórico de análises diferencia o sistema como uma plataforma flexível, voltada tanto a pesquisadores quanto a usuários não técnicos que desejam compreender o impacto das técnicas de pré-processamento textual.

De modo geral, os resultados obtidos evidenciam a eficiência, adaptabilidade e aplicabilidade prática do sistema proposto, confirmando os objetivos estabelecidos. A combinação entre uma interface responsiva e um *backend* resultou em uma ferramenta que alia clareza visual e controle analítico. Em comparação a soluções tradicionais, a aplicação se destaca pela personalização e usabilidade, constituindo uma contribuição relevante para as áreas de mineração de textos e Processamento de Linguagem Natural (PLN).



4 CONSIDERAÇÕES FINAIS OU CONCLUSÃO

O desenvolvimento do sistema *web* integrado a uma *API* para pré-processamento e análise textual demonstrou êxito no cumprimento dos objetivos propostos neste trabalho. A ferramenta mostrou-se eficiente, acessível e funcional, oferecendo ao usuário a possibilidade de inserir textos manualmente ou por meio de *upload* de arquivos *.txt*, com autonomia para selecionar e ordenar as etapas de processamento. Os testes realizados comprovaram a capacidade da aplicação em transformar textos brutos em dados estruturados e consistentes, possibilitando a identificação de padrões linguísticos relevantes por meio de rankings e representações gráficas.

A interface, projetada com foco na usabilidade, aliada à estrutura modular do algoritmo, tornou o sistema acessível a diferentes perfis de usuários, desde estudantes e pesquisadores até profissionais de diversas áreas, estimulando a autonomia na exploração das técnicas de Processamento de Linguagem Natural (PLN). Além disso, o desempenho estável e a integração com o banco de dados garantiram a confiabilidade da aplicação, assegurando a persistência das análises e o gerenciamento eficiente das informações.

A ferramenta se destaca por sua simplicidade de uso e flexibilidade, configurando-se como um recurso relevante para o ensino, a pesquisa e a aplicação prática em mineração de textos. Sua arquitetura modular e escalável também favorece expansões futuras, permitindo a incorporação de novos algoritmos, como lematização, análise de sentimentos e classificação automática, além de melhorias nos recursos visuais e semânticos.

Além disso, para versões futuras, pretende-se a inclusão de métricas simples de desempenho e usabilidade, adequadas ao escopo de um projeto de ensino médio. Por exemplo, podem ser incorporadas medições do tempo de processamento de cada etapa e do tempo total de execução, permitindo avaliar diferenças de desempenho conforme o tamanho do texto. Além disso, pequenas avaliações de usabilidade, como questionários curtos baseados em itens da escala *SUS* (*System*



Usability Scale).

Em síntese, o sistema desenvolvido representa um avanço significativo na simplificação do acesso às técnicas de pré-processamento textual, unindo rigor teórico e aplicação prática em uma plataforma interativa, moderna e funcional. O L&M Pré-Processamento Textual evidencia a importância de soluções tecnológicas acessíveis no contexto da mineração de textos, ao aproximar o usuário das etapas analíticas.

REFERÊNCIAS

ARANHA, Christian; PASSOS, Emmanuel. A tecnologia de mineração de textos. **Revista Eletrônica de Sistemas de Informação**, v. 5, n. 2, 2006.

HAN, Jiawei; PEI, Jian; TONG, Hanghang. **Data mining: concepts and techniques**. Morgan kaufmann, 2022.

PEZZINI, Anderson. Mineração de textos: conceito, processo e aplicações. **Revista Brasileira De Contabilidade E Gestão**, v. 5, n. 10, p. 58-61, 2017.

REATEGUI, Eliseo *et al.* Sobek: A text mining tool for educational applications. *In: Proceedings of the International Conference on Data Science (ICDATA)*. The Steering Committee of The World Congress in Computer Science, Computer Engineering and Applied Computing (WorldComp), 2011. p. 1.

REIS, Elismar Vicente dos. **Proposta de metodologia para abordagem terminológica da análise de domínio baseada em mineração de texto**: uma aplicação na ciência da informação. 2023. 151 f. Tese (Doutorado) - Curso de Programa de Pós-Graduação em Ciência da Informação, Universidade Estadual Paulista, Marília, 2023.

SOUZA, Allan Rocha de; SCHIRRU, Luca; ALVARENGA, Miguel Bastos. Mineração de textos e dados na pesquisa em saúde: reflexões sobre direitos autorais. **Cadernos de Saúde Pública**, v. 40, p. e00169023, 2024.