

INSTITUTO FEDERAL
PARANÁ



Ministério da Educação

INSTITUTO FEDERAL DO PARANÁ
TÉCNICO EM INFORMÁTICA

LINCOLN MAGGINI MAURO
MATHEUS MENDES LOURENÇO

**SISTEMA INGRADO A UMA INTERFACE WEB PARA PRÉ-
PROCESSAMENTO TEXTUAL: L&M PRÉ-
PROCESSAMENTO TEXTUAL**

LINCOLN MAGGINI MAURO
MATHEUS MENDES LOURENÇO

**SISTEMA INGRADO A UMA INTERFACE WEB PARA PRÉ-
PROCESSAMENTO TEXTUAL: L&M PRÉ-
PROCESSAMENTO TEXTUAL**

Projeto Final de Curso apresentado ao Instituto Federal do Paraná (IFPR), Campus Jacarezinho, como requisito parcial de avaliação no Curso Técnico em Informática.

Orientador: Prof. Me. Héber Renato Fadel de Moraes

Jacarezinho
2025

LINCOLN MAGGINI MAURO
MATHEUS MENDES LOURENÇO

**SISTEMA INGRADO A UMA INTERFACE WEB PARA PRÉ-
PROCESSAMENTO TEXTUAL: L&M PRÉ-
PROCESSAMENTO TEXTUAL**

Projeto Final de Curso apresentado ao Instituto Federal do Paraná (IFPR), Campus Jacarezinho, como requisito parcial de avaliação no Curso Técnico em Informática, com conceito igual a _____, conferida pela Banca Examinadora formada pelos professores:

Orientador: Prof. Me. Héber Renato Fadel de Moraes
Instituto Federal do Paraná

Prof. Dr. Elismar Vicente dos Reis
Instituto Federal do Paraná

Jacarezinho, 09 de dezembro de 2025.

Dedicamos este trabalho às nossas famílias e a todas as pessoas que, de alguma forma, estiveram ao nosso lado e tornaram possível a concretização deste objetivo, especialmente às nossas namoradas, pelo apoio constante e encorajamento.

AGRADECIMENTOS

Registro minha profunda gratidão a todos os docentes e profissionais da área educacional que, ao longo da minha trajetória acadêmica, desempenharam papel fundamental em minha formação intelectual e humana. Cada ensinamento, orientação e incentivo recebidos foram essenciais para o desenvolvimento do pensamento crítico, da responsabilidade e do compromisso com o conhecimento.

De modo especial, agradeço às pessoas com quem tive a oportunidade de atuar em atividades acadêmicas, pesquisas e projetos, cuja orientação paciente e dedicação foram determinantes para o aprendizado que hoje levo comigo.

Agradeço, ainda, à minha namorada, pelo apoio incondicional, companheirismo e compreensão durante todas as etapas deste trabalho.

Matheus Mendes Lourenço

AGRADECIMENTOS

Agradeço primeiramente a Jeová Deus, que tem sido minha fonte de força, coragem e direção em todos os momentos da minha vida. Foi Ele quem me sustentou quando parecia que eu não ia aguentar e renovou meu ânimo quando pensei em desistir. Muitas vezes, lembrei-me das palavras de Filipenses 4:13: “Para todas as coisas tenho forças graças àquele que me dá poder.” E realmente senti isso, cada passo que consegui dar foi porque Jeová me fortaleceu e me guiou. Sou profundamente grato por todo o cuidado, amor e apoio constantes, por tudo o que Ele já fez e por tudo o que continua fazendo por mim a cada dia.

Agradeço também a todos os professores que fizeram parte da minha trajetória acadêmica no IFPR. Que contribuíram e muito para meu crescimento, oferecendo apoio, incentivo e ensinamentos que eu nem imaginava que iria aprender antes de ingressar no curso.

Registro também minha gratidão especial aos meus orientadores. Sua dedicação, paciência e disponibilidade foram fundamentais para o meu desenvolvimento pessoal e acadêmico. Sou grato pelas orientações, pela ajuda com o aproveitamento de carga horária, pelas contribuições que possibilitaram a conclusão antecipada do curso e pelo apoio constante durante a elaboração deste trabalho.

Estendo meus agradecimentos à minha família: meus pais e meu irmão, pelo apoio que me deram ao longo de toda a minha formação. Sem a ajuda, compreensão e incentivo deles, nada disso teria sido possível.

Por fim, agradeço imensamente à minha incrível namorada. Nos últimos meses, sua presença, carinho e incentivo foram essenciais para que eu mantivesse a motivação e não desistisse. Ela esteve ao meu lado nos dias bons e, principalmente, nos dias difíceis; comemorou comigo cada pequena conquista, ouviu minhas preocupações e sempre me lembrou do quanto eu era capaz. Sou profundamente grato por todo o apoio, amor, compreensão, por acreditar em mim quando eu mais precisei e por continuar sendo uma das maiores razões pelas quais eu sigo em frente.

Lincoln Maggini Mauro

Não tente fazer, faça ou não faça.

MAURO, Lincoln Maggini Mauro; LOURENÇO, Matheus Mendes. Sistema Integrado a uma Interface Web para Pré-Processamento Textual: L&M Pré-Processamento Textual. 2025. 48 f. Projeto Final de Curso (Técnico em Informática) – Instituto Federal do Paraná, Campus Jacarezinho, Jacarezinho, 2025.

RESUMO

Este relatório apresenta, de forma cronológica, o desenvolvimento de projetos voltados à mineração de textos e à análise de domínio, realizados ao longo da formação técnica no Instituto Federal do Paraná – Campus Jacarezinho. A trajetória inicia-se com a criação de um algoritmo em Python para pré-processamento textual, utilizando bibliotecas como NLTK, re, unicodedata e Matplotlib. Essa primeira versão foi capaz de limpar, transformar e analisar textos por meio de técnicas como remoção de stopwords, normalização, stemming e geração de rankings e nuvens de palavras, estabelecendo a base conceitual e computacional para os trabalhos seguintes. Na etapa seguinte, o projeto evoluiu para o desenvolvimento inicial de uma API construída em Python/Flask, integrada a uma interface web voltada à interação dinâmica com o algoritmo. Essa versão permitiu ao usuário enviar textos manualmente ou via upload de arquivos, aplicar etapas configuráveis de pré- processamento e visualizar os resultados de forma modular e segmentada. A interface passou a exibir ranking de termos, nuvens de palavras e saídas intermediárias, tornando o sistema mais acessível a diferentes perfis de usuários. Dando continuidade, foi desenvolvido um banco de dados relacional em MySQL para registrar usuários, textos enviados e configurações de processamento, que possibilitou a autenticação, armazenamento de históricos, recuperação de análises anteriores e maior organização dos resultados, ampliando o escopo do sistema para além de uma ferramenta experimental e aproximando-o de uma aplicação completa de mineração de textos. O trabalho mais recente consolidou todas as versões anteriores em uma plataforma integrada denominada L&M Pré-Processamento Textual. Essa versão final reúne API, interface web responsiva e banco de dados, oferecendo ao usuário autonomia total para ordenar as etapas de processamento, visualizar transformações em tempo real, gerar gráficos, salvar seus processos e realizar downloads individuais ou completos. A modularidade do sistema, aliada ao foco em usabilidade, tornou a aplicação estável, interativa e adequada para fins educacionais, experimentais e analíticos. Parte desses trabalhos foi submetida a eventos científicos regionais, recebendo destaque por sua inovação, aplicabilidade e contribuição didática.

Palavras-chave: Relatório. Mineração de Texto. Análise Textual. API. Interface Web.

LISTA DE ABREVIATURAS E SIGLAS

ABNT	Associação Brasileira de Normas Técnicas
API	Application Programming Interface (Interface de programação de aplicativos)
IFPR	Instituto Federal do Paraná
NLTK	Natural Language Toolkit (Kit de ferramentas de linguagem natural)
PLN	Processamento de Linguagem Natural

SUMÁRIO

INTRODUÇÃO	11
REFERÊNCIAS	13
APÊNDICES	14
APÊNDICE I	15
APÊNDICE II	28
APÊNDICE III	33
APÊNDICE IV	36

INTRODUÇÃO

O avanço contínuo das tecnologias digitais tem intensificado a produção de dados textuais em larga escala, exigindo ferramentas capazes de organizar, interpretar e extrair informações relevantes desses conteúdos não estruturados. Nesse cenário, a mineração de textos surge como uma área fundamental dentro da Ciência da Computação, permitindo a aplicação de técnicas de processamento, análise e visualização para identificar padrões linguísticos e apoiar a tomada de decisões. (Han; Pei; Tong, 2022; Souza; Schirru; Alvarenga, 2024) Associada a esses processos, encontra-se o Processamento de Linguagem Natural (PLN), responsável por dotar sistemas computacionais da capacidade de manipular a linguagem humana de forma mais estruturada (Reis, 2023).

Além de sua aplicabilidade em contextos corporativos, acadêmicos e científicos, a mineração de textos tem sido amplamente empregada no desenvolvimento de ferramentas educacionais e experimentais, principalmente quando se busca criar soluções personalizadas que vão além dos softwares convencionais (Pezzini, 2017). Nesse contexto, o desenvolvimento de algoritmos próprios, APIs e interfaces web demonstra-se essencial para ampliar a autonomia do usuário e possibilitar análises adaptáveis a diferentes domínios.

Este relatório tem como objetivo apresentar, de maneira sequencial e fundamentada, os projetos desenvolvidos ao longo do período letivo no Instituto Federal do Paraná – Campus Jacarezinho. Esses trabalhos concentram-se no estudo e implementação de técnicas de mineração de textos, abrangendo desde algoritmos iniciais de pré-processamento até a criação de sistemas completos com interface web e banco de dados. A seguir, são descritos, em ordem cronológica, os quatro projetos desenvolvidos:

O primeiro trabalho (LOURENÇO *et al.*, 2024), intitulado “Criação Inicial de Algoritmos para Análise de Domínio Baseada em Mineração de Texto em Python”, apresenta o desenvolvimento inicial de um algoritmo dedicado ao pré-processamento textual. A proposta consistiu em aplicar técnicas como remoção de stopwords, normalização, stemming e geração automática de rankings e nuvens de palavras, utilizando bibliotecas como NLTK, re, unicodedata e Matplotlib. Este trabalho foi apresentado na V Jornada de Estudos em Tecnologia da Informação (J3T1) em 2024.

Em continuidade, o segundo trabalho (LOURENÇO *et al.*, 2025a), “Desenvolvimento Inicial de uma API e uma Interface Web para Análise de Domínio Baseada em Mineração de Texto em Python”, introduz uma aplicação web conectada a uma API construída em Python/Flask. O sistema possibilitou que o usuário digitasse ou

enviasse arquivos .txt, aplicasse etapas configuráveis e visualizasse os resultados de forma modular e dinâmica, integrando o algoritmo anterior a um ambiente mais acessível e interativo. Este projeto foi apresentado no Seminário de Ensino, Extensão, Pesquisa e Inovação do Campus Jacarezinho (SE²PINJAC), em 2024.

O terceiro trabalho (MAURO *et al.*, 2025b), intitulado “Desenvolvimento Inicial de um Banco de Dados para uma Interface Web para Análise de Domínio Baseada em Mineração de Texto”, apresenta a estruturação de um banco de dados relacional em MySQL destinado ao armazenamento de usuários, textos, etapas aplicadas e configurações de análise. Essa etapa foi fundamental para permitir autenticação, histórico de processamentos e gerenciamento completo dos dados gerados pelo sistema. Este trabalho foi apresentado no VI Encontro Anual de Iniciação Científica Júnior (EAIC Jr.) em 2025.

Por fim, o trabalho mais recente (LOURENÇO *et al.*, 2025c), “Sistema Integrado a uma Interface Web para Pré-Processamento Textual: L&M Pré-Processamento Textual”, consolida e amplia as versões anteriores. Esta versão final integra API, interface web responsiva e banco de dados, oferecendo visualização em tempo real, controle total sobre a ordem das etapas, geração de estatísticas e gráficos, download de resultados, histórico de análises e ambiente completo de pré-processamento textual. O sistema demonstra estabilidade, usabilidade e caráter didático, destacando seu potencial para aplicações educacionais, acadêmicas e analíticas. Este trabalho foi apresentado na VI Jornada de Estudos em Tecnologia da Informação (J3T1) em 2025.

Com base na evolução dos quatro trabalhos desenvolvidos, é possível identificar algumas direções para o aprimoramento do sistema em versões futuras. Entre elas, destacam-se a inclusão de técnicas mais avançadas de Processamento de Linguagem Natural, como lematização, análise de sentimentos e classificadores automáticos. Também podem ser incorporadas métricas de desempenho e novas formas de visualização dos dados. Além disso, melhorias na interface e no gerenciamento do histórico de análises podem tornar o sistema ainda mais completo e adequado para aplicações educacionais, acadêmicas e profissionais. Outra possível melhoria no sistema consiste na implementação de uma página de administrador, que permite gerenciar usuários, acompanhar e manter análises realizadas, além de gerar estatísticas gerais de uso do sistema, contribuindo para um gerenciamento mais robusto, apoiando assim o crescimento estável do sistema.

Os trabalhos referenciados ao longo da seção estão listados na seção anexos (compreendida dos anexos I até IV), na ordem em que confere às referências.

REFERÊNCIAS

HAN, Jiawei; PEI, Jian; TONG, Hanghang. **Data mining: concepts and techniques**. Morgan kaufmann, 2022.

SOUZA, Allan Rocha de; SCHIRRU, Luca; ALVARENGA, Miguel Bastos. Mineração de textos e dados na pesquisa em saúde: reflexões sobre direitos autorais. **Cadernos de Saúde Pública**, v. 40, p. e00169023, 2024.

PEZZINI, Anderson. Mineração de textos: conceito, processo e aplicações. **Revista Brasileira De Contabilidade E Gestão**, v. 5, n. 10, p. 58-61, 2017.

REIS, Elismar Vicente dos. **Proposta de metodologia para abordagem terminológica da análise de domínio baseada em mineração de texto: uma aplicação na ciência da informação**. 2023. 151 f. Tese (Doutorado) - Curso de Programa de Pós-Graduação em Ciência da Informação, Universidade Estadual Paulista, Marília, 2023.

LOURENÇO, Matheus Mendes; MAURO, Lincoln Maggini; DE MORAIS, Héber Renato Fadel; REIS, Elismar Vicente dos. **CRIAÇÃO INICIAL DE ALGORITMOS PARA ANÁLISE DE DOMÍNIO BASEADA EM MINERAÇÃO DE TEXTO EM PYTHON**. In: V JORNADA DE ESTUDOS EM TECNOLOGIA DA INFORMAÇÃO (J3T1), 2024, Jacarezinho. Jacarezinho: Instituto Federal do Paraná, 2024.

LOURENÇO, Matheus Mendes; MAURO, Lincoln Maggini; DE MORAIS, Héber Renato Fadel; REIS, Elismar Vicente dos. **DESENVOLVIMENTO INICIAL DE UMA API E UMA INTERFACE WEB PARA ANÁLISE DE DOMÍNIO BASEADA EM MINERAÇÃO DE TEXTO EM PYTHON**. In: SEMINÁRIO DE ENSINO, EXTENSÃO, PESQUISA E INOVAÇÃO, 2025, Jacarezinho. Anais. Jacarezinho: Instituto Federal do Paraná, 2025a.

MAURO, Lincoln Maggini; LOURENÇO, Matheus Mendes; DE MORAIS, Héber Renato Fadel; REIS, Elismar Vicente dos. **DESENVOLVIMENTO INICIAL DE UM BANCO DE DADOS PARA UMA INTERFACE WEB PARA ANÁLISE DE DOMÍNIO BASEADA EM MINERAÇÃO DE TEXTO**. In: VI ENCONTRO ANUAL DE INICIAÇÃO CIENTÍFICA JÚNIOR (EAIC JR 2025), 2025. UEL, Londrina, 2025b.

LOURENÇO, Matheus Mendes; MAURO, Lincoln Maggini; DE MORAIS, Héber Renato Fadel; REIS, Elismar Vicente dos. **SISTEMA INTEGRADO A UMA INTERFACE WEB PARA PRÉ-PROCESSAMENTO TEXTUAL: L&M PRÉ-PROCESSAMENTO TEXTUAL**. In: VI JORNADA DE ESTUDOS EM TECNOLOGIA DA INFORMAÇÃO (J3T1), 2025, Jacarezinho. Jacarezinho: Instituto Federal do Paraná, 2025c.

APÊNDICES

APÊNDICE I



CRIAÇÃO INICIAL DE ALGORITMOS PARA ANÁLISE DE DOMÍNIO BASEADA EM MINERAÇÃO DE TEXTO EM PYTHON

Matheus Mendes Lourenço

*Instituto Federal do Paraná Campus Jacarezinho, Curso Técnico em Informática,
matheusmendeslourenco@gmail.com*

Lincoln Maggini Mauro

*Instituto Federal do Paraná Campus Jacarezinho, Curso Técnico em Informática,
lincoln.maggini@gmail.com*

Héber Renato Fadel de Moraes

Instituto Federal do Paraná Campus Jacarezinho, heber.moraes@ifpr.edu.br

Elismar Vicente dos Reis

Instituto Federal do Paraná Campus Jacarezinho, elismar.reis@ifpr.edu.br

RESUMO

A mineração de textos emerge como uma técnica essencial na análise de grandes volumes de dados textuais, permitindo a extração de informações relevantes e a identificação de padrões complexos em dados não estruturados. Este projeto explora algumas das principais etapas e ferramentas disponíveis para a aplicação dessa técnica, destacando sua relevância em áreas como análise de dados, categorização de documentos e interpretação de padrões. A justificativa para este trabalho surge da necessidade de lidar com grandes volumes de dados não estruturados de forma eficaz, em um momento em que o volume de informações geradas por diversos setores, como, pesquisa acadêmica, análise de mercado e processamento de linguagem natural, tem crescido exponencialmente. Os objetivos deste trabalho incluem o desenvolvimento inicial de um algoritmo que, a partir de um conjunto de arquivos de texto, é capaz de realizar o pré-processamento necessário, aplicar algumas técnicas de mineração de texto, como a contagem de frequências de termos e a geração de nuvens de palavras, a fim de proporcionar visualizações gráficas que facilitem a análise dos resultados. Para isso, foram utilizadas bibliotecas da linguagem de programação Python, como o NLTK (Natural Language Toolkit), que fornece recursos avançados de processamento de linguagem natural, a biblioteca de expressões regulares (re), o Matplotlib, usado para criar visualizações gráficas, e o Unicodedata, que permite normalizar textos eliminando caracteres especiais. O



algoritmo desenvolvido processa arquivos de texto (.txt), realizando pré-processamento por meio da remoção de números, caracteres especiais, acentuações e palavras comuns, conhecidas também como stopwords, além da aplicação do método Snowball Stemmer, uma técnica que reduz palavras ao seu radical linguístico, facilitando assim a análise de variações linguísticas. Como resultado, foi possível gerar representações gráficas, como nuvens de palavras e rankings de frequência de termos com o método Snowball Stemmer aplicado ou não, que auxiliam na interpretação e análise de dados.

Palavras-chave: Mineração de textos; Python; Análise de dados.

INTRODUÇÃO

A análise de domínio baseada em mineração de texto tem se tornado uma abordagem cada vez mais relevante no contexto da Ciência da Computação, especialmente quando se busca compreender, explorar e extrair informações valiosas a partir de grandes volumes de dados textuais. Estudos destacam que o avanço das tecnologias de processamento de dados, aliado à crescente disponibilidade de informações não estruturadas, exige o desenvolvimento de ferramentas que automatizam a análise e a extração de conhecimento (Han, Pei & Kamber, 2012). Nesse cenário, a mineração de texto se destaca como uma técnica fundamental para a identificação de padrões, tópicos e relacionamentos subjacentes em conjuntos de dados textuais, sendo amplamente utilizada em contextos acadêmicos e industriais (Pedroso, Lima & Neto, 2017; Souza, Schirru & Alvarenga, 2020).

A mineração de texto envolve a aplicação de algoritmos que permitem a extração de informações úteis de textos não estruturados. A análise de domínio, por sua vez, foca na identificação e extração de conhecimento específico de um determinado campo de aplicação, sendo essencial para áreas como a categorização de documentos, análise de sentimentos e recomendações de produtos (Safdari et al., 2021; Pedroso, Lima & Neto, 2017). Embora ferramentas prontas para mineração de texto estejam amplamente disponíveis, estudos apontam que o desenvolvimento de algoritmos personalizados pode oferecer vantagens significativas, como maior precisão ao atender às necessidades de domínios



específicos e maior flexibilidade para ajustes finos em processos de pré-processamento e análise dos dados (Rezende, 2005; Souza, Schirru & Alvarenga, 2020).

Este projeto propõe a criação inicial de algoritmos para a análise de domínio baseada em mineração de texto utilizando a linguagem de programação Python. O foco está na implementação de um sistema capaz de processar e analisar textos de forma eficiente, utilizando bibliotecas como NLTK, re, unicodedata, os e matplotlib. A escolha dessas ferramentas visa permitir a realização de tarefas essenciais no processamento de texto, como a limpeza de dados, remoção de “stopwords”, normalização e a análise de frequência de termos. A utilização do *Snowball Stemmer*, uma técnica que reduz as palavras ao seu radical, será aplicada como parte da análise linguística, facilitando a compreensão das variações linguísticas dentro de um domínio específico.

A motivação para este projeto surge da necessidade de lidar com grandes volumes de dados não estruturados de forma eficaz, em um momento em que o volume de informações geradas por diversas fontes tem crescido exponencialmente. Embora ferramentas prontas para mineração de texto já estejam disponíveis, elas frequentemente não são adaptáveis o suficiente para a análise específica de determinados domínios, o que pode resultar em soluções menos precisas e eficientes. Assim, a proposta deste projeto é o desenvolvimento de um algoritmo inicial que não só automatize o processo de mineração de texto, mas também ofereça flexibilidade e customização para atender a diferentes necessidades, permitindo a adaptação e expansão conforme o domínio de aplicação se desenvolve.

O principal objetivo deste trabalho é desenvolver um algoritmo que, a partir de um conjunto de arquivos de texto, seja capaz de realizar o pré-processamento necessário, aplicar técnicas de mineração de texto, como a contagem de frequências de termos e a geração de nuvens de palavras, a fim de proporcionar visualizações gráficas que facilitem a análise dos resultados. Além disso, o sistema é projetado para possibilitar uma compreensão mais profunda do domínio de análise, identificando as principais características dos textos, como a frequência de



termos específicos e os padrões que emergem a partir do uso de algoritmos de stemming e técnicas de classificação.

Nos próximos tópicos, serão detalhados os materiais e métodos empregados no desenvolvimento do algoritmo proposto, bem como os resultados obtidos durante a execução do algoritmo, destacando a aplicação do método “Snowball Stemmer” e outras ferramentas para a análise de dados textuais.

MATERIAIS E MÉTODOS

A metodologia deste projeto foi desenvolvida com o objetivo de criar um processo eficiente para o processamento e análise de textos utilizando a linguagem de programação Python. O foco esteve no uso de bibliotecas especializadas, que otimizam e simplificam as etapas de limpeza, transformação e visualização de dados textuais, além de fornecer suporte à manipulação de arquivos e diretórios.

Entre as principais ferramentas empregadas, destaca-se o **NLTK (Natural Language Toolkit)**, amplamente utilizado no campo do processamento de linguagem natural, que oferece recursos como tokenização, stemming e lematização. Para etapas de limpeza e pré-processamento, a biblioteca **re** desempenhou um papel essencial ao permitir a manipulação de expressões regulares, facilitando a remoção de padrões indesejados no texto. A biblioteca **unicodedata** também foi utilizada para normalizar os textos, removendo caracteres especiais e garantindo maior uniformidade dos dados.


Além dessas, a biblioteca **os** foi integrada ao projeto para gerenciar eficientemente os arquivos e diretórios do sistema operacional. Essa ferramenta permitiu organizar e acessar os arquivos de texto na pasta específica destinada ao processamento, garantindo que as etapas do algoritmo fossem executadas de maneira estruturada. Para a visualização dos resultados, utilizou-se a **Matplotlib**, uma biblioteca robusta para a criação de gráficos, que viabilizou a geração de representações visuais claras e intuitivas, como gráficos de frequência e nuvens de palavras.

O algoritmo foi estruturado para cobrir desde a leitura inicial dos arquivos até



a visualização final, com cada etapa detalhadamente planejada. O fluxo do processo, juntamente com um fluxograma explicativo, será apresentado a seguir na Figura 1, destacando como as ferramentas foram aplicadas e os resultados obtidos em cada fase do processamento.

Figura 1 - Fluxograma Mineração de texto em python



Fonte: Adaptada de Reis (2023)

O algoritmo descrito tem como objetivo processar arquivos de texto (.txt) armazenados em uma pasta específica denominada “ArquivosTXT”. A primeira etapa do processo é a limpeza do texto, um passo crucial para a mineração de dados. Essa etapa utiliza expressões regulares para identificar e remover elementos indesejados, como números, caracteres especiais, acentos e diferenças de capitalização, garantindo que todas as palavras sejam convertidas para letras minúsculas.

A remoção de números é realizada por meio de um padrão específico que identifica dígitos individuais ou sequências numéricas consecutivas. Essas sequências são substituídas por uma string vazia, resultando em uma versão limpa



da palavra, sem qualquer elemento numérico. De forma similar, a remoção de caracteres especiais utiliza a biblioteca “re” para identificar símbolos e pontuações que não sejam letras, números ou espaços em branco. Esses caracteres são eliminados, deixando o texto exclusivamente composto por caracteres alfanuméricos.

A etapa seguinte é a remoção de acentos, implementada com a biblioteca unicodedata. O algoritmo decompõe cada palavra em seus caracteres de base e em seus acentos, tratando-os como entidades separadas. Em seguida, os acentos são identificados por sua categoria Unicode e removidos, resultando em palavras que preservam apenas os caracteres essenciais. Essa abordagem garante uma maior uniformidade no processamento linguístico.

Após a limpeza estrutural, o texto é convertido inteiramente para letras minúsculas, padronizando a capitalização e facilitando comparações subsequentes. O texto é então segmentado em palavras individuais, transformando a string original em uma lista manipulável. Para refinar ainda mais os dados, o algoritmo remove as palavras comuns, conhecidas como “stopwords”. Esse processo percorre a lista de palavras e elimina aquelas consideradas irrelevantes, como artigos, preposições e conjunções, preservando apenas os termos mais significativos.

O *Snowball Stemmer* é então aplicado para reduzir as palavras às suas raízes. Essa técnica é particularmente útil em análises linguísticas, pois minimiza variações de palavras causadas por pluralização, tempos verbais e outros fatores gramaticais. Embora o stemmer não seja utilizado para gerar a nuvem de palavras, ele permite observar o impacto de cada etapa ao longo do processo, exibindo os resultados intermediários no terminal.

A visualização dos resultados segue um fluxo sequencial: o texto original é exibido e, em seguida, os dados processados em cada etapa, incluindo a remoção de números, caracteres especiais, acentos, conversão para minúsculas, separação em palavras, remoção de *stopwords* e aplicação do *Snowball Stemmer*. Para consolidar os resultados, o algoritmo adota a técnica de “*Bag of Words*”, que transforma o texto em um conjunto de palavras, contabilizando a frequência de cada termo sem considerar sua ordem. Esses termos são convertidos em objetos da



classe "termo" para serem utilizados em operações como contagem de co-ocorrências e agrupamento por frequência.

Os termos são então organizados em um ranking decrescente, indicando a quantidade de ocorrências de cada um no texto. Por fim, é gerada uma nuvem de palavras, destacando visualmente os termos mais frequentes com tamanhos proporcionais à sua relevância. Essa visualização é criada tanto com quanto sem a aplicação do *Snowball Stemmer*, permitindo comparações entre as versões.

Todo o processo se beneficia de bibliotecas robustas como NLTK, re, unicodedata e Matplotlib, que fornecem ferramentas essenciais para a execução de tarefas complexas. Técnicas como remoção de números, caracteres especiais e acentos, combinadas com o uso do stemmer, garantem um alto nível de limpeza e organização do texto. A criação de nuvens de palavras e rankings de frequência oferece uma visão clara e intuitiva dos dados analisados, permitindo insights profundos sobre a composição textual e a relevância dos termos.

Em resumo, o processamento automatizado de textos descrito representa uma abordagem estruturada e eficiente para a análise linguística e mineração de dados textuais. As etapas cuidadosamente implementadas, desde a limpeza inicial até a visualização final em nuvens de palavras e rankings, demonstram como ferramentas computacionais podem extrair informações relevantes de grandes volumes de dados. O uso combinado de bibliotecas especializadas e técnicas avançadas, como o *Snowball Stemmer*, não apenas organiza e simplifica os textos, mas também possibilita uma análise mais precisa e significativa. Esse processo, ao transformar textos brutos em dados úteis, destaca seu potencial para aplicações em áreas como pesquisa acadêmica, análise de mercado e processamento de linguagem natural.

ANÁLISE E DISCUSSÃO DOS RESULTADOS

A apresentação dos resultados permite avaliar o desempenho do algoritmo desenvolvido na análise de textos em formato .txt. Durante o processamento, diversas etapas de limpeza e transformação foram aplicadas ao arquivo .txt. O



V JORNADA DE ESTUDOS EM TECNOLOGIA DA INFORMAÇÃO

TENDÊNCIAS E PERSPECTIVAS EM TECNOLOGIA DA INFORMAÇÃO
03 A 06 DE DEZEMBRO 2024

objetivo foi identificar padrões textuais e extrair informações relevantes. A seguir, são mostradas as saídas geradas pelo algoritmo, incluindo exemplos com e sem a aplicação do *Snowball Stemmer*, destacando o impacto de cada etapa na qualidade da análise. Como entrada foi utilizada uma parte do próprio resumo deste artigo para ser exemplificada as saídas do algoritmo, de acordo com o Fluxograma apresentado na Figura 1, assim, as Figuras 2 e 3 apresentam as saídas obtidas após a execução do algoritmo, sem e com a aplicação do *Snowball Stemmer*.



Figura 2 - Saída dos processamentos de texto realizada, parte 01.

Texto Original

A mineração de textos emerge como uma técnica essencial na análise de grandes volumes de dados textuais, permitindo a extração de informações relevantes e a identificação de padrões complexos em dados não estruturados. Este projeto explora algumas das principais etapas e ferramentas disponíveis para a aplicação dessa técnica, destacando sua relevância em áreas como análise de dados, categorização de documentos e interpretação de padrões.

Texto sem Números

A mineração de textos emerge como uma técnica essencial na análise de grandes volumes de dados textuais, permitindo a extração de informações relevantes e a identificação de padrões complexos em dados não estruturados. Este projeto explora algumas das principais etapas e ferramentas disponíveis para a aplicação dessa técnica, destacando sua relevância em áreas como análise de dados, categorização de documentos e interpretação de padrões.

Texto sem Caracteres Especiais

A mineração de textos emerge como uma técnica essencial na análise de grandes volumes de dados textuais permitindo a extração de informações relevantes e a identificação de padrões complexos em dados não estruturados Este projeto explora algumas das principais etapas e ferramentas disponíveis para a aplicação dessa técnica destacando sua relevância em áreas como análise de dados categorização de documentos e interpretação de padrões

Texto sem Acentos

A mineracao de textos emerge como uma tecnica essencial na analise de grandes volumes de dados textuais permitindo a extracao de informacoes relevantes e a identificacao de padroes complexos em dados nao estruturados Este projeto explora algumas das principais etapas e ferramentas disponiveis para a aplicacao dessa tecnica destacando sua relevancia em areas como analise de dados categorizacao de documentos e interpretacao de padroes

Texto em Letras Minusculas

a mineracao de textos emerge como uma tecnica essencial na analise de grandes volumes de dados textuais permitindo a extracao de informacoes relevantes e a identificacao de padroes complexos em dados nao estruturados este projeto explora algumas das principais etapas e ferramentas disponiveis para a aplicacao dessa tecnica destacando sua relevancia em areas como analise de dados categorizacao de documentos e interpretacao de padroes

Texto sem Stopwords

mineracao textos emerge tecnica essencial analise grandes volumes dados textuais permitindo extracao informacoes relevantes identificacao padroes complexos dados nao estruturados projeto explora algumas principais etapas ferramentas disponiveis aplicacao dessa tecnica destacando relevancia areas analise dados categorizacao documentos interpretacao padroes

Texto com Snowball Stemmer

mineraca text emerg tecnic essencial analis grand volum dad textu permit extraca informaco relev identificaca padro complex dad nao estrutur projet explor algum princip etap ferrament disponiv aplicaca dess tecnic destac relevanc are analis dad categorizaca document interpreta padro

Ranking das 10 Palavras mais Frequentes sem Snowball Stemmer

```
Texto Original: 1 Resumo.txt
Ranking das 10 palavras mais frequentes:
1. dados: 3
2. analise: 2
3. padroes: 2
4. tecnica: 2
5. algumas: 1
6. aplicacao: 1
7. areas: 1
8. categorizacao: 1
9. complexos: 1
10. dessa: 1
```




V JORNADA DE ESTUDOS EM TECNOLOGIA DA INFORMAÇÃO

TENDÊNCIAS E PERSPECTIVAS EM TECNOLOGIA DA INFORMAÇÃO
03 A 06 DE DEZEMBRO 2024

Figura 3 - Saída dos processamentos de texto realizada, parte 01.



Fonte: Desenvolvido pelos autores (2024);

O algoritmo desenvolvido é flexível e pode ser utilizado para processar outros textos escolhidos pelo usuário. Basta adicionar os arquivos .txt desejados na pasta designada para processamento, permitindo uma análise adaptada a diferentes contextos e objetivos. Essa versatilidade torna a ferramenta útil para aplicações variadas, como classificação de documentos, identificação de tendências textuais e apoio à tomada de decisões baseada em dados textuais.

CONSIDERAÇÕES FINAIS

Como conclusão, os objetivos propostos pelo projeto foram alcançados, com a implementação de um algoritmo inicial para análise de domínio baseada em mineração de texto que lê arquivos .txt de uma pasta específica, realiza o processamento textual por meio de filtragem e criação de listas de palavras, e exibe os resultados em forma de ranking e nuvem de palavras, incluindo a aplicação do



método *snowball stemmer* para análise linguística.

Os resultados obtidos com a implementação do algoritmo demonstram benefícios claros para o usuário, como a facilidade de organizar grandes volumes de texto, identificar padrões por meio do *ranking* de palavras e visualizar as informações de forma intuitiva com a nuvem de palavras. A aplicação do *Snowball Stemmer* acrescenta um nível adicional de análise, reduzindo palavras às suas raízes e permitindo interpretações mais precisas. Esses ganhos tornam a ferramenta uma solução prática e eficiente para a análise de dados textuais em diversos domínios.

Para aprimorar o projeto, planeja-se o desenvolvimento de uma interface *web* que permitirá ao usuário incluir arquivos, configurar formatos de saída e acompanhar visualmente cada etapa do processo de mineração de textos. Essa plataforma online poderá consolidar os resultados das diferentes etapas de processamento, oferecendo um resumo geral de todos os arquivos analisados, com representações gráficas como nuvens de palavras e *rankings*. Além disso, o aprimoramento do sistema inclui a expansão de funcionalidades, como a aplicação de outras técnicas de mineração de texto e maior flexibilidade na configuração dos parâmetros. Esse avanço facilitará o acesso e a utilização do sistema por usuários com diferentes níveis de familiaridade com análise de dados textuais, ampliando a aplicabilidade do projeto em cenários reais.

REFERÊNCIAS

HAN, J.; PEI, J.; KAMBER, M. *Data mining: concepts and techniques*. 3. ed. Amsterdam: Elsevier, 2012.

PEDROSO, J. B.; LIMA, J. S.; NETO, A. M. *Análise de dados e mineração de texto: uma abordagem aplicada*. São Paulo: Editora Ciência e Tecnologia, 2017.

REIS, Elismar Vicente dos. *Proposta de metodologia para abordagem terminológica da análise de domínio baseada em mineração de texto: uma aplicação na Ciência da Informação*. 2023. 151 p. Tese (Doutorado) – Universidade Estadual Paulista



V JORNADA DE ESTUDOS EM TECNOLOGIA DA INFORMAÇÃO

TENDÊNCIAS E PERSPECTIVAS EM TECNOLOGIA DA INFORMAÇÃO
03 A 06 DE DEZEMBRO 2024

(UNESP), Marília, 2023.

SAFDARI, S.; DELDAR, M.; KHOSRAVI, A. et al. *Text mining for healthcare applications: challenges and opportunities*. *Journal of Medical Informatics*, v. 72, p. 85-92, 2021.

SOUZA, R. S.; SCHIRRU, R. P.; ALVARENGA, R. S. *Análise de texto e mineração de dados na prática*. 2. ed. Belo Horizonte: Editora UFMG, 2020

APÊNDICE II



DESENVOLVIMENTO INICIAL DE UMA API E UMA INTERFACE WEB PARA ANÁLISE DE DOMÍNIO BASEADA EM MINERAÇÃO DE TEXTO EM PYTHON

Matheus Mendes Lourenço¹, Lincoln Maggini Mauro¹, Héber Renato Fadel de Moraes¹, Elismar Vicente dos Reis¹ (Orientador)

IFPR - Campus Jacarezinho¹
heber.morais@ifpr.edu.br

Resumo

A mineração de textos aplica técnicas para classificar dados e revelar padrões em textos, conectando-se ao Processamento de Linguagem Natural (PLN), que busca ensinar computadores a interpretar a linguagem humana. Este projeto objetivou desenvolver uma ferramenta web com API em Python e Flask para pré-processamento textual que fosse acessível a usuários com diferentes níveis técnicos. A ferramenta permite envio de arquivos completos .txt ou inserção do texto diretamente na página web, realizando transformações como remoção de *stop words*, normalização e *stemming*. Os resultados obtidos demonstram a possibilidade de extração de padrões ou tendências nos textos em linguagem natural, exibindo-os de forma modular e dinâmica. Ainda é possível realizar o download do texto processado por completo. Até essa etapa, a ferramenta demonstrou cumprir o objetivo proposto na facilitação da mineração de texto. Futuras melhorias incluem integração com banco de dados e sistema de usuários.

Palavras-chave: Mineração de Texto, Análise Textual, Python, API, Interface Web.

Introdução

Com o crescimento exponencial da produção de dados textuais provenientes das mais diversas fontes, como redes sociais, artigos científicos, notícias, relatórios empresariais, dentre outros, surge a necessidade de ferramentas capazes de interpretar, organizar e extrair informações relevantes a partir de conteúdos não estruturados (Moraes; Ambrósio, 2007). Nesse cenário, a mineração de textos se consolida como uma área estratégica da Ciência da Computação, com forte conexão ao Processamento de Linguagem Natural (PLN), ramo da inteligência artificial que busca dotar as máquinas da capacidade de compreender e manipular a linguagem humana. Por meio da aplicação de algoritmos e métodos estatísticos, essa técnica permite identificar padrões, classificar dados e revelar informações implícitas em textos, viabilizando a análise inteligente de grandes volumes de informação (Vieira; Lopes, 2010).

A abordagem de análise de domínio por meio da mineração de texto tem ganhado destaque crescente em diversas áreas, inclusive na Ciência da Computação, especialmente quando o objetivo é compreender, explorar e extrair conhecimento de grandes quantidades de dados textuais. Alguns trabalhos indicam que, com o avanço das tecnologias de processamento de dados e o aumento da disponibilidade de informações não estruturadas, torna-se essencial o desenvolvimento de ferramentas capazes de automatizar a análise e a extração de conhecimento (Han; Pei; Kamber, 2012; Reis, 2023). Apesar da existência de ferramentas consolidadas para esse tipo de tarefa, estudos indicam que soluções personalizadas tendem a apresentar melhores resultados em domínios específicos, ao oferecer maior precisão, flexibilidade e adaptabilidade (Souza; Schirru; Alvarenga, 2020; Reis, 2023). Isso justifica o desenvolvimento de novos algoritmos e interfaces que considerem as peculiaridades linguísticas de cada área de conhecimento.

Neste contexto, o presente projeto se propõe a dar os primeiros passos no desenvolvimento de uma API e de uma interface web para análise de domínio baseada em mineração de texto. A proposta visa oferecer uma solução simples, acessível e funcional, tanto para usuários iniciantes quanto para pesquisadores e profissionais de várias áreas, com foco em pré-processamento textual e análise de frequência de termos. Assim, o principal objetivo deste trabalho é implementar uma aplicação que permita o processamento de textos e a extração de padrões linguísticos relevantes.



Metodologia

A metodologia utilizada para a construção de uma API em Python, utilizou o framework Flask, responsável pelo processamento dos textos enviados pelos usuários. Inicialmente, o sistema foi projetado para permitir a entrada de dados por meio do upload de arquivos no formato .txt ou por inserção do texto diretamente na página web, garantindo flexibilidade na utilização da ferramenta. Para atender às necessidades específicas de limpeza e transformação textual, foram implementadas diversas etapas configuráveis, que o usuário pode selecionar e ordenar conforme seu interesse. Conforme Reis (2023), essas etapas incluem: remoção de números, eliminação de caracteres especiais, remoção de acentuações, exclusão de stopwords, conversão de todo o texto para letras minúsculas e aplicação da técnica de stemming para reduzir as palavras às suas raízes.

A linguagem Python foi utilizada em conjunto com bibliotecas específicas voltadas ao processamento textual, como o NLTK, responsável pela identificação e remoção de *stopwords* e pela aplicação do *stemming*; a biblioteca “re”, empregada na utilização de expressões regulares para a filtragem de padrões textuais indesejados; e a biblioteca “unicodedata”, utilizada para a normalização de caracteres e remoção de acentos, garantindo uniformidade ao texto analisado. A API processa o texto seguindo a ordem estabelecida pelo usuário, garantindo modularidade e controle sobre o fluxo das transformações.

Os resultados são retornados de forma segmentada e exibidos dinamicamente na interface web, com recursos que facilitam a visualização e cópia dos textos processados em cada etapa. Complementando essa exibição interativa, a aplicação incorpora funcionalidades analíticas importantes, como a geração de ranking e nuvem de palavras dos termos mais frequentes, que auxiliam na visualização e compreensão dos padrões textuais extraídos. Para melhor representar a lógica do sistema, o fluxograma apresentado na Figura 1 representa o encadeamento modular do processo do sistema de pré-processamento textual, detalhando cada etapa da interação entre usuário, interface gráfica e API.




Figura 1 - Fluxograma do processo de pré-processamento textual (Fonte: os autores).

Resultados e Discussão

Com base na estrutura metodológica descrita, foi possível desenvolver uma aplicação funcional que alia processamento linguístico automatizado a uma interface intuitiva e interativa. A seguir, são apresentados os principais resultados obtidos com a implementação do sistema, destacando-se a forma como a interface gráfica se integra ao funcionamento da API para viabilizar, de maneira acessível e eficiente, o pré-processamento e a análise textual.

Conforme apresentado na Figura 2, a interface gráfica permite ao usuário tanto o upload de arquivos no formato .txt quanto a inserção manual de textos por meio de uma caixa de texto. Após o envio do conteúdo, o usuário pode selecionar e ordenar, de forma personalizada, as transformações linguísticas que deseja aplicar como, remoção de stop words, remover números, aplicar stemming, dentre outros. Essa flexibilidade no encadeamento das etapas contribui diretamente para a adaptação da análise a diferentes objetivos e contextos.

Figura 2 - Tela de envio do texto e transformações do sistema desenvolvido (Fonte: os autores).

Figura 3 - Tela de resultados do sistema (Fonte: os autores).

3



Em comparação com outras soluções disponíveis, a aplicação se destaca por sua simplicidade de uso, adaptabilidade ao contexto do usuário e caráter educativo. Ao oferecer total controle sobre as etapas de pré-processamento, a ferramenta torna-se uma aliada valiosa tanto para análises técnicas quanto para o ensino de conceitos fundamentais de Processamento de Linguagem Natural (PLN) e mineração de texto. De forma geral, os resultados obtidos validam os objetivos propostos inicialmente, demonstrando a funcionalidade e aplicabilidade da ferramenta no cenário de análise textual. Para trabalhos futuros, planeja-se a integração com um sistema de banco de dados que permita o cadastro de usuários, armazenamento de consultas anteriores e o uso de filtros semânticos ou classificadores automáticos, ampliando as possibilidades de análise e tornando o sistema ainda mais robusto e inteligente.

A comparação entre textos com e sem a aplicação do Snowball Stemmer evidenciou diferenças significativas na forma como os termos são reduzidos e agrupados. Termos como “organização”, “organizar” e “organizado” foram unificados em uma mesma raiz, impactando diretamente os rankings e a nuvem de palavras. A análise quantitativa, via ranking e nuvem de palavras, permitiu visualizar com clareza os termos mais frequentes em cada amostra, tornando o processo analítico mais acessível também a usuários não técnicos. Comparada a outras ferramentas, a aplicação se sobressai pela simplicidade, adaptabilidade e caráter educativo. Ao oferecer controle total sobre as etapas do pré-processamento e visualização dos efeitos gerados, mostra-se eficaz tanto como solução técnica quanto como recurso didático para experimentações em PLN e mineração de texto. Por fim, os resultados validam os objetivos propostos e abrem caminho para futuras melhorias, como filtros semânticos, integração com banco de dados e uso de classificadores automáticos para análises mais avançadas.

Considerações Finais

O desenvolvimento da aplicação web integrada a uma API para análise textual baseada em mineração de texto e Processamento de Linguagem Natural (PLN) cumpriu com êxito os objetivos propostos. A ferramenta mostrou-se eficaz, acessível e funcional, permitindo aos usuários o envio de arquivos .txt ou entrada manual de texto diretamente na página Web, com flexibilidade para selecionar e ordenar diferentes etapas de pré-processamento, como remoção de stopwords, aplicação de stemming, entre outras. Os testes realizados confirmaram a capacidade do sistema de transformar textos brutos em dados estruturados, destacando padrões linguísticos relevantes por meio de rankings e nuvens de palavras. A visualização modular dos resultados, aliada à interface intuitiva, torna o processo acessível a públicos diversos, incluindo aqueles com pouca familiaridade técnica. O sistema ainda se mostrou adaptável a diferentes domínios e objetivos analíticos, podendo ser facilmente reutilizado com novos arquivos e ajustado conforme a necessidade do usuário.

A ferramenta se destaca pela simplicidade de uso, adaptabilidade e potencial didático, sendo útil tanto para pesquisadores quanto para estudantes e profissionais que desejam explorar ou aplicar técnicas de PLN de forma prática. Além disso, o comportamento da aplicação está alinhado a boas práticas já descritas na literatura, especialmente no uso de técnicas como o stemming para melhorar a eficiência das análises. Como continuidade do trabalho, pode-se realizar a integração de funcionalidades adicionais, como autenticação de usuários, armazenamento de históricos de análise e implementação de filtros semânticos e classificadores automáticos. Essas melhorias visam ampliar o potencial de uso da ferramenta e torná-la ainda mais robusta para aplicações avançadas de análise textual. Em suma, este projeto representa um passo inicial na construção de uma solução acessível e eficaz para pré-processamento e exploração de textos, com potencial de crescimento e aplicação em contextos educacionais, acadêmicos e profissionais.

Referências

HAN, J.; PEI, J.; KAMBER, M. Data mining: concepts and techniques. 3. ed. Amsterdam: Elsevier, 2012.

MORAIS, E. A. M.; AMBRÓSIO, A. P. L. Mineração de textos. Goiânia: Instituto de Informática, Universidade Federal de Goiás, 2007. Relatório Técnico – INF_005/07.

REIS, Elismar Vicente dos. Proposta de metodologia para abordagem terminológica da análise de domínio baseada em mineração de texto: uma aplicação na ciência da informação. Universidade Estadual Paulista (Unesp), 2023.

SOUZA, R. S.; SCHIRRU, R. P.; ALVARENGA, R. S. Análise de texto e mineração de dados na prática. 2. ed. Belo Horizonte: Editora UFMG, 2020.

VIEIRA, R.; LOPES, L. Processamento de linguagem natural e o tratamento computacional de linguagens científicas. In: PERNA, C. L.; DELGADO, H. K.; FINATTO, M. J. (orgs.). Linguagens especializadas em corpora: modos de dizer e interfaces de pesquisa. Porto Alegre: EDIPUCRS, 2010. p. 183–201.

APÊNDICE III



DESENVOLVIMENTO INICIAL DE UM BANCO DE DADOS PARA UMA INTERFACE WEB PARA ANÁLISE DE DOMÍNIO BASEADA EM MINERAÇÃO DE TEXTO

Lincoln Maggini Mauro, Matheus Mendes Lourenço, Héber Renato Fadel de Moraes, Elismar Vicente dos Reis

lincoln.maggini@gmail.com, elismar.reis@ifpr.edu.br

Universidade Estadual de Londrina

Ciências Exatas e da Terra; Ciência da Computação.

Palavras-chave: Mineração de Texto, Análise Textual, API, Interface Web, Banco de dados.

Resumo

A mineração de textos, consolidada como uma área estratégica da Ciência da Computação, utiliza algoritmos de Processamento de Linguagem Natural (PLN) para extrair informações úteis e padrões implícitos em textos não estruturados provenientes de fontes como artigos científicos, redes sociais e notícias. A análise de domínio, por meio dessa abordagem, busca extrair conhecimento específico de um determinado campo, tornando-se pertinente para a compreensão de grandes volumes de dados textuais. Nesse contexto, o desenvolvimento de soluções personalizadas em mineração de textos torna-se propício, sendo este o foco do presente trabalho. Este projeto tem como objetivo desenvolver um banco de dados para integração com uma interface web de análise de domínio baseada em mineração de texto, previamente desenvolvida pelos autores, com o intuito de possibilitar o armazenamento, gerenciamento, configurações de análise e autenticação de usuários. A metodologia do projeto seguiu etapas progressivas, contemplando desde a concepção inicial até a implementação prática. O processo incluiu fases de desenvolvimento de prototipagem, permitindo validar funcionalidades e ajustar o sistema com base nos testes realizados. Inicialmente, elaborou-se um algoritmo em Python para o pré-processamento de textos, responsável por aplicar transformações linguísticas essenciais para a análise. Posteriormente, foi criada uma API em Python utilizando o framework Flask, integrada a uma interface web, permitindo ao usuário inserir textos manualmente ou realizar o upload de arquivos no formato .txt. Essa interface possibilita selecionar e ordenar as transformações a serem aplicadas, tornando o sistema mais interativo e adaptável a diferentes análises. Em seguida, foi estruturado o banco de dados relacional em MySQL, destinado a armazenar tanto os textos processados quanto as configurações definidas pelo usuário. Foram criadas três tabelas principais: Usuários, contendo dados de cadastro como nome, e-mail e senha; Textos, registrando o conteúdo original enviado pelo usuário; e

Realização



Apoio Institucional



Apoio Financeiro





Etapas de Processamento, detalhando as transformações aplicadas em cada execução, sempre vinculadas a um texto específico. Para a construção do sistema foram utilizadas as seguintes tecnologias: Python, com as bibliotecas NLTK, re e unicodedata, aplicadas no processamento, manipulação e análise textual; Flask, utilizado para a criação da API de integração com a interface web; MySQL, empregado no gerenciamento do banco de dados; e HTML, CSS e JavaScript, aplicados no desenvolvimento da interface web. Diante disso, desenvolveu-se um banco de dados relacional integrado a uma aplicação web, permitindo o armazenamento e gerenciamento eficientes dos resultados de análise de textos, as transformações aplicadas e os resultados gerados, como rankings de frequência de palavras. A criação do banco de dados foi um passo crucial para viabilizar as próximas etapas do desenvolvimento, que incluem a implementação de autenticação de usuários, armazenamento de históricos de análise e a criação de funcionalidades avançadas. Em suma, o desenvolvimento do banco de dados para a interface web, não apenas atendeu aos objetivos iniciais, mas também o preparou para futuras melhorias, que contribuirão significativamente para a evolução da plataforma e sua aplicação prática na análise de texto

Realização



Apoio Institucional



Apoio Financeiro



APÊNDICE IV



SISTEMA INTEGRADO A UMA INTERFACE WEB PARA PRÉ-PROCESSAMENTO TEXTUAL: L&M PRÉ-PROCESSAMENTO TEXTUAL

Matheus Mendes Lourenço

*Instituto Federal do Paraná Campus Jacarezinho, Curso Técnico em Informática,
matheusmendeslourenco@gmail.com*

Lincoln Maggini Mauro

*Instituto Federal do Paraná Campus Jacarezinho, Curso Técnico em Informática,
lincoln.maggini@gmail.com*

Héber Renato Fadel de Moraes

Instituto Federal do Paraná Campus Jacarezinho, heber.morais@ifpr.edu.br

Elismar Vicente dos Reis

Instituto Federal do Paraná Campus Jacarezinho, elismar.reis@ifpr.edu.br

RESUMO

Diante do crescimento contínuo da produção de textos em ambientes digitais torna-se necessário ferramentas capazes de organizar e tratar grandes volumes de informação textual. O pré-processamento textual constitui etapa fundamental desse fluxo, ao eliminar ruídos e padronizar elementos linguísticos para análises subsequentes. Entretanto, muitas das soluções disponíveis demandam conhecimentos técnicos avançados, o que limita seu uso por estudantes e profissionais sem experiência na área. Diante desse cenário, este trabalho apresenta o “L&M Pré-Processamento Textual”, uma aplicação integrada a uma interface *web* desenvolvida para tornar acessíveis técnicas de limpeza e transformação de texto de maneira simples, interativa e intuitiva. O sistema permite ao usuário inserir textos manualmente ou por *upload* de arquivo, selecionar e ordenar etapas de pré-processamento e visualizar, de forma imediata, os resultados de cada transformação. A implementação adotou *Flask* para a *API* e tecnologias *web* (*HTML*, *CSS* e *JavaScript*) no *front-end*, assegurando comunicação eficiente entre servidor e interface. Foram utilizadas bibliotecas consolidadas para remoção de *stopwords*, *stemming*, normalização e exclusão de caracteres indesejados, além de recursos para geração automática de estatísticas e gráficos de frequência. Adicionalmente, implementou-se um banco de dados que possibilita cadastro e autenticação de usuários, com armazenamento e consulta do histórico de processamentos. Os testes demonstraram que o sistema opera de forma estável e responsiva em textos de distintos tamanhos, oferecendo autonomia ao usuário e



facilitando o aprendizado das técnicas de pré-processamento textual. Conclui-se que o “L&M Pré-processamento Textual” representa uma ferramenta prática, acessível para análise e mineração de textos em ambientes web, ao conciliar eficiência, usabilidade e potencial para expansão futura.

Palavras-chave: Pré-processamento Textual; Interface Web; Mineração de Texto; API; Análise Textual.

1 INTRODUÇÃO

O avanço das tecnologias de Processamento de Linguagem Natural (PLN) e de Mineração de Textos tem transformado profundamente as formas de extração, interpretação e utilização da informação em diversos contextos, que vão desde a pesquisa científica até o ambiente corporativo. O volume crescente de dados textuais gerados diariamente, provenientes de redes sociais, artigos acadêmicos, documentos empresariais e publicações jornalísticas torna indispensável o desenvolvimento de ferramentas capazes de lidar com informações não estruturadas, permitindo identificar padrões, tendências e relações linguísticas relevantes (Han; Pei; Tong, 2022; Souza; Schirru; Alvarenga, 2024). Aranha e Passos (2006, p. 3) destacam que “o crescimento do armazenamento de dados não estruturados, devido ao avanço da mídia digital, propiciou o desenvolvimento das técnicas de mineração de textos”, reforçando a necessidade de sistemas capazes de estruturar esses dados para análise.

Nesse cenário, técnicas de análise de texto têm ganhado protagonismo em áreas como saúde, educação e opinião pública, impulsionadas pela necessidade de interpretar grandes quantidades de dados em formato textual (Pezzini, 2017). A mineração de textos consolida-se, assim, como uma das principais vertentes da Ciência da Computação, ao aplicar métodos estatísticos e linguísticos voltados à extração de conhecimento a partir de documentos de texto. De modo complementar, o PLN busca dotar os sistemas computacionais da capacidade de compreender e manipular a linguagem humana, aproximando a comunicação entre humanos e



máquinas e possibilitando aplicações como análise de sentimentos, categorização de documentos e extração de informações específicas (Reis, 2023).

Essas potencialidades tornam indispensável o desenvolvimento de sistemas capazes de realizar, de forma automatizada e flexível, processos como normalização, limpeza e transformação linguística de dados textuais. Contudo, apesar dos avanços teóricos, a aplicação prática dessas técnicas ainda exige conhecimento técnico em programação e carece de interfaces acessíveis e intuitivas, que ofereçam autonomia ao usuário no controle do fluxo de pré-processamento. Diante dessa lacuna, este trabalho propõe o desenvolvimento de um sistema *web* para análise textual, que possibilita ao usuário escolher e ordenar as etapas de pré-processamento, como remoção de *stopwords*, *stemming* e normalização, além de visualizar dinamicamente os resultados e gerenciar o histórico de análises realizadas.

Assim, o objetivo deste artigo é apresentar a versão final do sistema desenvolvido, destacando sua arquitetura baseada em *API*, interface *web* e banco de dados, bem como suas funcionalidades de análise e persistência de dados, evidenciando sua contribuição para a autonomia e a flexibilidade analítica na área de mineração textual.

Nos tópicos seguintes, são apresentados os materiais, métodos e tecnologias empregados na implementação do sistema, seguidos da análise dos resultados obtidos e da discussão de suas funcionalidades.

2 MATERIAIS E MÉTODOS


A metodologia adotada neste projeto teve como objetivo desenvolver uma ferramenta completa de pré-processamento e análise textual em ambiente *web*, integrando um algoritmo modular em *Python* a uma interface interativa e responsiva. O sistema foi projetado para que o usuário pudesse selecionar, personalizar e salvar diferentes etapas de processamento textual.



O desenvolvimento do sistema seguiu o modelo de prototipagem incremental, que consiste na criação de versões sucessivas e funcionais do produto, avaliadas e aprimoradas conforme os resultados obtidos e o *feedback* dos testes. Inicialmente, foram elaborados protótipos dos algoritmos, seguidos pela implementação da *API* e da interface *web*, culminando na integração com o banco de dados.

Para representar a lógica do sistema, foram elaborados diagramas que descrevem suas principais interações. O Diagrama de Caso de Uso (Figura 1) apresenta a relação entre os atores (usuário e usuário logado) e as funcionalidades centrais, como processar texto, realizar *login*, realizar *download*, salvar processamento, dentre outros.

Figura 1 – Diagrama de caso de uso




Fonte: Desenvolvido pelos autores (2025).

A modelagem do banco de dados foi elaborada por meio de um Diagrama Entidade-Relacionamento (DER) (Figura 2), composto pelas entidades usuário, texto e etapa. O relacionamento entre essas entidades permite armazenar as informações de cada processamento, vinculadas ao respectivo usuário. O usuário possui um ou



mais processos; cada processo contém várias etapas (com tipo, ordem e resultado textual).

Figura 2 – Diagrama entidade-relacionamento (DER)



Fonte: Desenvolvido pelos autores (2025).

A *API* do sistema foi desenvolvida em linguagem *Python*, amplamente empregada na área de Processamento de Linguagem Natural (PLN) devido ao suporte de bibliotecas consolidadas. Entre elas, destaca-se o *NLTK* (*Natural Language Toolkit*), utilizado na remoção de *stopwords* e na aplicação de *stemming*, técnica que reduz as palavras às suas raízes, promovendo uniformidade lexical. A biblioteca *re* foi empregada na utilização de expressões regulares para filtragem e exclusão de padrões indesejados, como números, pontuações e caracteres especiais. Já a biblioteca *unicodedata* foi utilizada na normalização de caracteres e remoção de acentuações, garantindo consistência textual.

O framework *Flask* foi selecionado para a construção da *API* em razão de sua leveza e modularidade, possibilitando a criação de rotas específicas para *upload* de textos, execução de etapas de pré-processamento, exportação de resultados e gerenciamento de usuários autenticados. Essa estrutura assegura uma comunicação eficiente entre o *backend* e o *frontend*, permitindo que cada solicitação do usuário seja processada de forma independente e segura.



No lado do cliente, o sistema foi desenvolvido com *HTML5*, *CSS3* e *JavaScript*, integrando bibliotecas e *frameworks* que aprimoram a experiência do usuário. O *Bootstrap* foi empregado para garantir responsividade e padronização visual da interface, enquanto o *Petite-Vue* proporcionou reatividade leve e eficiente, atualizando dinamicamente os resultados conforme o processamento é executado. A biblioteca *Sortable.js* foi incorporada para permitir que o usuário organize as etapas do algoritmo de forma intuitiva, utilizando o recurso de arrastar e soltar (*drag and drop*). Além disso, a *Chart.js* foi utilizada para a geração de gráficos interativos, representando visualmente estatísticas textuais, como o *ranking* de frequência de termos. Ao final de cada operação, são geradas estatísticas automáticas, como número total de palavras, contagem de caracteres (com e sem espaço) e *ranking* de frequência de termos, exibidas no painel de resultados.

O algoritmo de pré-processamento textual foi desenvolvido para processar tanto textos digitados manualmente quanto arquivos enviados pelo usuário. Após a inserção dos dados, o algoritmo executa as etapas selecionadas conforme a ordem definida na interface. Cada etapa é implementada como uma função independente dentro da *API*, o que assegura modularidade e facilita futuras expansões do sistema.

Os resultados intermediários e finais podem ser visualizados, copiados, baixados individualmente ou exportados em formato *.txt* ou *PDF*. Usuários autenticados têm ainda a possibilidade de salvar seus processamentos no banco de dados, acessando posteriormente um histórico que permite renomear, excluir ou reabrir análises anteriores.


Em síntese, o conjunto de técnicas, ferramentas e diagramas empregados neste projeto possibilitou a criação de uma aplicação *web* escalável e de fácil utilização, que combina métodos de pré-processamento textual com visualização interativa e persistência de dados. O resultado é um sistema *web* que une teoria e prática, aplicando conceitos de mineração de texto e PLN em uma plataforma acessível e adaptável a diferentes contextos analíticos.

3 ANÁLISE E DISCUSSÃO DOS RESULTADOS

Com base na metodologia apresentada, foi possível desenvolver uma aplicação funcional que integra o processamento linguístico automatizado a uma interface gráfica intuitiva e interativa, permitindo ao usuário configurar, executar e visualizar o processamento de textos conforme suas necessidades específicas.

A tela inicial e a tela de *login* (Figura 3) apresentam: acessar a tela do sistema de processamento, voltada à experimentação das funcionalidades, sem a possibilidade de salvar os processos no banco de dados. A tela de login ou cadastro possibilitam que novos usuários criem uma conta com informações básicas.

Figura 3 – Página inicial do sistema e tela de *login* e cadastro



Fonte: Desenvolvido pelos autores (2025).

Após o *login*, o usuário é direcionado para sua área pessoal, onde pode visualizar e editar seus dados cadastrais e acessar o sistema com todas as funcionalidades disponíveis.



Na página do sistema e seleção de etapas do processamento (Figura 4), o usuário pode inserir um texto manualmente ou realizar o *upload* de um arquivo no formato *.txt*, além de escolher e ordenar livremente as etapas de pré-processamento, como remoção de números, caracteres especiais, acentuação, *stopwords* e aplicação do *snowball stemmer*. A interface permite também a reordenação dinâmica das etapas. Essa flexibilidade torna o sistema personalizável, permitindo observar o impacto de cada transformação textual em tempo real.

Figura 4 – Página do sistema e seleção de etapas do processamento

Faça o upload do seu texto aqui:

Arraste um arquivo .txt aqui ou clique para selecionar

1 - O Pré-processamento textual é uma etapa crucial em qualquer projeto de Mineração de Textos (Text Mining) ou Processamento de Linguagem Natural (PLN). Ele transforma dados de texto brutos, que são frequentemente caóticos e cheios de ruídos, em um formato limpo e estruturado que os algoritmos de aprendizado de máquina podem processar de forma eficiente. Sem essa etapa, a qualidade da análise seria comprometida, levando a resultados imprecisos e insights enganosos.

Etapas Disponíveis

- + Remover Números
- + Remover Caracteres Especiais
- + Remover Acentos
- + Converter para Minúsculas
- + Remover Stopwords
- + Aplicar Stemming
- + Ranking de palavras e gráficos

Ordem de Execução (Clique e arraste)

- Remover Números
- Remover Caracteres Especiais
- Converter para Minúsculas
- Aplicar Stemming
- Ranking de palavras e gráficos

Máx. Palavras: 10 Gráfico: Nenhum

Usar Exemplo Processar


Fonte: Desenvolvido pelos autores (2025).

Na página do sistema, na seção de resultados de um processamento (Figura 5), são apresentados, logo após o usuário processar o texto, todas as etapas selecionadas, organizadas na sequência definida. Além disso, exibe-se o resultado final do processo, acompanhado do texto original, para facilitar a comparação entre



ambos. O usuário pode realizar o *download* de cada etapa ou o processo por completo e também copiar o texto sem precisar fazer *login*, mas precisa estar logado para salvar o processo. Além disso, é interessante ressaltar que o sistema pode exibir visualizações gráficas do processamento caso o usuário deseje. Por exemplo, podem ser gerados gráficos de nuvens de palavras e gráficos de barras, que auxiliam na análise dos dados processados, organizados com base no *ranking* da frequência de palavras.

Figura 5 – Página do sistema e resultados de um processamento



Fonte: Desenvolvido pelos autores (2025).

Durante os testes realizados, observou-se que a aplicação manteve desempenho estável mesmo com textos extensos, resultado da modularização da *API* em *Python/Flask*. O processamento sequencial e independente de cada etapa assegurou rápida renderização dos resultados. A comunicação entre a *API* e a



interface garantiu a consistência dos dados e a atualização das visualizações, proporcionando uma experiência de uso fluida e eficiente.

Em comparação com soluções já existentes, o sistema desenvolvido apresenta uma abordagem mais flexível e interativa. Ferramentas como o *Sobek Mining* (REATEGUI et al., 2011), embora executem tarefas de mineração textual, operam com uma sequência fixa de etapas e oferecem ao usuário resultados essencialmente estáticos, orientados à aplicação direta dos métodos já definidos na ferramenta. Esse tipo de estrutura, apesar de funcional para análises pontuais, reduz a possibilidade de adaptação do fluxo às necessidades específicas de cada usuário. Já o sistema proposto concede autonomia ao permitir a escolha e reorganização da ordem das etapas, possibilitando observar o impacto de cada transformação no texto processado. Além disso, enquanto o *Sobek Mining* não permite ajustar o *pipeline* nem visualizar resultados intermediários de forma dinâmica, o sistema desenvolvido torna essas etapas transparentes, permitindo maior experimentação. Como desvantagem, o sistema proposto ainda não abrange a variedade de técnicas de mineração textual presentes no *Sobek Mining*, que inclui métodos mais avançados e recursos adicionais, entretanto, sua flexibilidade, interatividade e foco na personalização representam vantagens significativas para usuários que desejam maior controle sobre o pré-processamento textual.

Além disso, a integração de recursos como nuvem de palavras dinâmica, rankings interativos e histórico de análises diferencia o sistema como uma plataforma flexível, voltada tanto a pesquisadores quanto a usuários não técnicos que desejam compreender o impacto das técnicas de pré-processamento textual.

De modo geral, os resultados obtidos evidenciam a eficiência, adaptabilidade e aplicabilidade prática do sistema proposto, confirmando os objetivos estabelecidos. A combinação entre uma interface responsiva e um *backend* resultou em uma ferramenta que alia clareza visual e controle analítico. Em comparação a soluções tradicionais, a aplicação se destaca pela personalização e usabilidade, constituindo uma contribuição relevante para as áreas de mineração de textos e Processamento de Linguagem Natural (PLN).



4 CONSIDERAÇÕES FINAIS OU CONCLUSÃO

O desenvolvimento do sistema *web* integrado a uma *API* para pré-processamento e análise textual demonstrou êxito no cumprimento dos objetivos propostos neste trabalho. A ferramenta mostrou-se eficiente, acessível e funcional, oferecendo ao usuário a possibilidade de inserir textos manualmente ou por meio de *upload* de arquivos *.txt*, com autonomia para selecionar e ordenar as etapas de processamento. Os testes realizados comprovaram a capacidade da aplicação em transformar textos brutos em dados estruturados e consistentes, possibilitando a identificação de padrões linguísticos relevantes por meio de rankings e representações gráficas.

A interface, projetada com foco na usabilidade, aliada à estrutura modular do algoritmo, tornou o sistema acessível a diferentes perfis de usuários, desde estudantes e pesquisadores até profissionais de diversas áreas, estimulando a autonomia na exploração das técnicas de Processamento de Linguagem Natural (PLN). Além disso, o desempenho estável e a integração com o banco de dados garantiram a confiabilidade da aplicação, assegurando a persistência das análises e o gerenciamento eficiente das informações.

A ferramenta se destaca por sua simplicidade de uso e flexibilidade, configurando-se como um recurso relevante para o ensino, a pesquisa e a aplicação prática em mineração de textos. Sua arquitetura modular e escalável também favorece expansões futuras, permitindo a incorporação de novos algoritmos, como lematização, análise de sentimentos e classificação automática, além de melhorias nos recursos visuais e semânticos.

Além disso, para versões futuras, pretende-se a inclusão de métricas simples de desempenho e usabilidade, adequadas ao escopo de um projeto de ensino médio. Por exemplo, podem ser incorporadas medições do tempo de processamento de cada etapa e do tempo total de execução, permitindo avaliar diferenças de desempenho conforme o tamanho do texto. Além disso, pequenas avaliações de usabilidade, como questionários curtos baseados em itens da escala *SUS* (*System*



Usability Scale).

Em síntese, o sistema desenvolvido representa um avanço significativo na simplificação do acesso às técnicas de pré-processamento textual, unindo rigor teórico e aplicação prática em uma plataforma interativa, moderna e funcional. O L&M Pré-Processamento Textual evidencia a importância de soluções tecnológicas acessíveis no contexto da mineração de textos, ao aproximar o usuário das etapas analíticas.

REFERÊNCIAS

ARANHA, Christian; PASSOS, Emmanuel. A tecnologia de mineração de textos. **Revista Eletrônica de Sistemas de Informação**, v. 5, n. 2, 2006.

HAN, Jiawei; PEI, Jian; TONG, Hanghang. **Data mining: concepts and techniques**. Morgan kaufmann, 2022.

PEZZINI, Anderson. Mineração de textos: conceito, processo e aplicações. **Revista Brasileira De Contabilidade E Gestão**, v. 5, n. 10, p. 58-61, 2017.

REATEGUI, Eliseo *et al.* Sobek: A text mining tool for educational applications. *In: Proceedings of the International Conference on Data Science (ICDATA)*. The Steering Committee of The World Congress in Computer Science, Computer Engineering and Applied Computing (WorldComp), 2011. p. 1.

REIS, Elismar Vicente dos. **Proposta de metodologia para abordagem terminológica da análise de domínio baseada em mineração de texto**: uma aplicação na ciência da informação. 2023. 151 f. Tese (Doutorado) - Curso de Programa de Pós-Graduação em Ciência da Informação, Universidade Estadual Paulista, Marília, 2023.

SOUZA, Allan Rocha de; SCHIRRU, Luca; ALVARENGA, Miguel Bastos. Mineração de textos e dados na pesquisa em saúde: reflexões sobre direitos autorais. **Cadernos de Saúde Pública**, v. 40, p. e00169023, 2024.